

BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT TP.HCM

KHOA CÔNG NGHỆ THÔNG TIN



HCMUTE

BÁO CÁO CUỐI KÌ

MÔN HỌC: LẬP TRÌNH PYTHON

ĐỀ TÀI

PHÂN TÍCH DỮ LIỆU HỆ THỐNG PHIM TRÊN NETFLIX

Giảng viên hướng dẫn: ThS. Trần Quang Khải

SVTH

MSSV

Lương Ngọc Huy

23133028

Nguyễn Đức Toàn

23133077

Trần Quốc Giảng

23133019

Nguyễn Đức Thịnh

23133073

Nguyễn Hữu Tâm

23133067

Mã lớp học phần: IPPA233277_07

Thành phố Hồ Chí Minh, tháng 12 năm 2024

DANH SÁCH THÀNH VIÊN THAM GIA ĐỒ ÁN

Đề tài: “Phân tích dữ liệu hệ thống phim trên Netflix”

STT	HỌ VÀ TÊN THÀNH VIÊN	MÃ SỐ SINH VIÊN	TỶ LỆ THAM GIA
1	Trần Quốc Giảng	23133019	100%
2	Lương Ngọc Huy	23133028	100%
3	Nguyễn Đức Thịnh	23133073	100%
4	Nguyễn Hữu Tâm	23133067	100%
5	Nguyễn Đức Toàn	23133077	100%

Ghi chú:

Tỷ lệ %: Mức độ phần trăm hoàn thành của từng sinh viên tham gia.

Trưởng nhóm: Trần Quốc Giảng

Nhận xét của giảng viên:

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

TP. Hồ Chí Minh, ngày ... tháng... năm 2024

Giảng viên ký tên

LỜI CẢM ƠN

Chúng em xin gửi lời cảm ơn sâu sắc đến thầy Trần Quang Khải, thầy đã tận tình giảng dạy trong suốt quá trình tìm hiểu và học tập môn Lập Trình Python. Trong từng buổi học, thầy đã nhiệt huyết trong từng lời giải đáp, những kiến thức, kỹ năng, tài liệu quý giá mà thầy đã truyền đạt học không chỉ là nền tảng cho quá trình thực hiện báo cáo cuối kì của nhóm mà còn là kiến thức nền tảng cho nhiều phần sau này.

Rất nhiều công sức và nỗ lực đã được bỏ ra, nhưng do chưa có kinh nghiệm trong việc xây dựng đề tài và những hạn chế về kiến thức, bài báo cáo này không tránh khỏi sai sót. Chúng em luôn sẵn sàng tiếp thu những ý kiến từ thầy để cải thiện bài báo cáo cũng như đề tài lần này.

Một lần nữa, chúng em xin bày tỏ lòng biết ơn đến thầy. Chúng em xin kính chúc thầy luôn dồi dào sức khỏe và đạt được nhiều thành công trong công việc.

Đại diện nhóm

Trần Quốc Giảng

MỤC LỤC

PHẦN 1: MỞ ĐẦU.....	1
1.1 Tính cấp thiết của đề tài.....	1
1.2 Mục tiêu nghiên cứu.....	2
1.3 Đối tượng và phạm vi nghiên cứu.....	2
PHẦN 2: NỘI DUNG.....	3
CHƯƠNG 1: TÓM TẮT CƠ SỞ LÝ THUYẾT.....	3
2.1 Tổng quan về lý thuyết.....	3
2.1.1 Thư viện Pandas.....	3
2.1.2 Thư viện Numpy.....	4
2.1.3 Thư viện Matplotlib.....	4
2.1.4 Thư viện Tkinter.....	5
CHƯƠNG 2: GIAI ĐOẠN PHÂN TÍCH VÀ XÂY DỰNG.....	6
2.1 Thu thập dữ liệu.....	6
2.1.1 Mô tả nguồn dữ liệu.....	6
2.1.2 Chi tiết tệp dữ liệu.....	7
2.2 Làm sạch dữ liệu.....	10
2.2.1 Xử lý giá trị null.....	11
2.2.2 Xử lý giá trị duplicated.....	13
2.2.3 Chuẩn hóa kiểu dữ liệu.....	14
2.2.4 Chuẩn hóa Dataframe.....	18
2.3. CRUD.....	21
2.3.1 Thêm dòng mới vào DataFrame.....	21
2.3.2 Đọc DataFrame.....	22
2.3.3 Cập nhật thông tin của một dòng trong DataFrame.....	22
2.3.4 Xóa một dòng khỏi DataFrame.....	22

2.4 Phân tích dữ liệu	23
2.5 Trực quan hóa dữ liệu	31
2.5.1 Phương thức plot_movies_shows_by_year	31
2.5.2 Phương thức plot_top_5_actors_by_genre	32
2.5.3 Phương thức plot_movie_tv_show_distribution_by_country	33
2.5.4 Phương thức plot_top_genres	34
2.5.5 Phương thức plot_movie_vs_tv_show_distribution	35
2.5.6 Phương thức plot_exclusive_movies_by_year	36
2.5.7 Phương thức plot_added_year_trend	38
2.5.8 Phương thức plot_duration_distribution	39
2.5.9 Phương thức plot_top_directors_by_rating	40
2.5.10 Phương thức plot_correlation_matrix_matrix	41
2.5.11 Phương thức plot_correlation_matrix_matrix()	42
CHƯƠNG 3: GIAI ĐOẠN THIẾT KẾ GIAO DIỆN	44
3.1 Menu chức năng	44
3.1.1 Tổng quan về menu chức năng	44
3.1.2 Chức năng của các menu con	46
3.1.3 Chức năng xuất dữ liệu và xem DataFrame hiện tại	47
3.1.4. Chức năng thoát chương trình	47
3.2 Xây dựng giao diện UI với thư viện Tkinter	47
3.2.1 Tổng quan về giao diện UI	47
3.2.2 Các nhóm chức năng trong giao diện	48
CHƯƠNG 4: KẾT QUẢ VÀ THẢO LUẬN	59
4.1 Phân tích kết quả	59
4.2 Đề xuất về cải tiến quy trình phân tích	59
4.3 Hướng phát triển tương lai	59

TÀI LIỆU THAM KHẢO.....	60
--------------------------------	-----------

MỤC LỤC HÌNH ẢNH

Hình 1: Mô tả kiểu dữ liệu in ra màn hình.....	8
Hình 2: Kết quả khi thực hiện in ra từ hàm <code>get_shape()</code>	9
Hình 3: Kết quả in ra của hàm <code>most_frequent_values()</code>	10
Hình 4: Kết quả trả về in ra từ hàm <code>get_overview()</code>	10
Hình 5: Các record chứa giá trị trùng lặp trong tập dữ liệu.....	11
Hình 6: Các record chứa giá trị NULL trong tập dữ liệu.....	11
Hình 7: Hiển thị các giá trị Null ra ngoài màn hình Console.....	12
Hình 8: Mô tả xuất ra màn hình khi xóa các giá trị NULL.....	13
Hình 9: Mô tả xuất ra màn hình từ hàm <code>showDup()</code>	13
Hình 11: Mô tả xuất ra màn hình kiểu dữ liệu từ DataFrame.....	14
Hình 12: Một số dòng Record ban đầu chưa được làm sạch từ cột <code>date_added</code>	15
Hình 13: Dữ liệu cột <code>date_added</code> sau khi thực hiện hàm <code>to_datetime()</code>	16
Hình 14: Mô tả xuất ra màn hình console của hàm <code>split_duration()</code>	17
Hình 15: Mô tả xuất ra màn hình Console kiểu dữ liệu của Dataframe.....	17
Hình 16: Cột “ <code>listed_in</code> ” trong tập dữ liệu gốc.....	18
Hình 17: Một số record gặp vấn đề về định dạng và kí tự trong tập dữ liệu gốc.....	19
Hình 18: Kết quả thay đổi sau khi thực hiện các function chuẩn hóa Dataframe.....	20
Hình 19: Kết quả sau khi chạy hàm <code>create_data()</code>	22
Hình 20: Mô tả xuất ra màn hình khi không tìm được <code>item_id</code> cần cập nhật dữ liệu.....	22
Hình 21: Nội dung file csv trước khi thực hiện hàm xóa.....	23
Hình 22: Nội dung file csv sau khi thực hiện hàm xóa.....	23
Hình 23: Kết quả xuất ra màn hình khi thực hiện hàm <code>count_movie()</code> và <code>count_tv_shows()</code>	25
Hình 24: Kết quả xuất ra màn hình khi thực hiện hàm <code>count_movies_and_shows_by_country()</code>	26
Hình 25: Kết quả xuất ra màn hình khi thực hiện hàm <code>average_duration_by_year()</code>	26
Hình 26: Kết quả xuất ra màn hình khi thực hiện hàm <code>average_duration_by_year()</code>	27
Hình 27: Kết quả xuất ra màn hình khi thực hiện hàm <code>count_by_year_added()</code>	28
Hình 28: Kết quả xuất ra màn hình khi thực hiện hàm <code>top_5_actors_by_genre()</code>	29
Hình 29: Kết quả xuất ra màn hình khi thực hiện hàm <code>top_5_directors_by_rating()</code>	30
Hình 30: Kết quả xuất ra màn hình khi thực hiện hàm <code>calculate_duration_statistics()</code>	30
Hình 31: Biểu đồ tròn (pie chart) để hiển thị tỷ lệ giữa phim (Movie) và chương trình TV (TV Show) trong dữ liệu Netflix.....	32
Hình 32: Biểu đồ phân tán (scatter plot) để biểu diễn sự phân bố của thời lượng (minutes) các phim và chương trình TV trên Netflix.....	33
Hình 33: Biểu đồ cột (bar chart) để biểu diễn số lượng phim và chương trình TV được phát hành theo từng năm.....	34
Hình 34: Biểu đồ đường kết hợp vùng tô (line plot with filled area) để biểu diễn xu hướng số lượng phim và chương trình TV được thêm vào Netflix theo từng năm.....	35
Hình 35: Biểu đồ đường (line plot) để hiển thị số lượng phim độc quyền do Netflix phát hành qua các năm.....	36
Hình 36: Biểu đồ cột ngang (horizontal bar chart) để hiển thị các thể loại phổ biến nhất trên Netflix, dựa trên số lượng xuất hiện.....	37

Hình 37: Biểu đồ cột (bar chart) để hiển thị Top 5 diễn viên phổ biến nhất trong từng thể loại phim, được trình bày dưới dạng nhiều biểu đồ nhỏ (subplots), mỗi biểu đồ đại diện cho một thể loại.....	38
Hình 38: Biểu đồ cột ngang (horizontal bar chart) để hiển thị Top 1 đạo diễn có số lượng phim nhiều nhất trong mỗi loại đánh giá (rating).....	39
Hình 39: Biểu đồ cột (bar chart) để hiển thị Top 10 quốc gia sản xuất nhiều phim và chương trình TV nhất trên Netflix.....	40
Hình 40: Ma trận tương quan (correlation matrix) để trực quan hóa mức độ tương quan giữa các thể loại phim truyền hình.....	42
Hình 42: Giao diện chức năng Overview.....	44
Hình 43: Giao diện chức năng Data Cleaning.....	44
Hình 44: Giao diện chức năng CRUD.....	45
Hình 45: Giao diện tổng quan của ứng dụng.....	45
Hình 46: Giao diện phần mềm với thư viện Tkinter.....	48
Hình 47: Giao diện nhóm chức năng CLEANING.....	48
Hình 48: Thông báo từ messagebox khi tiến hành xử lý các giá trị Null.....	48
Hình 49: Thông báo từ messagebox khi đã xử lý các giá trị Null trước đó.....	49
Hình 50: Thông báo từ messagebox khi tiến hành xử lý các giá trị Duplicate.....	49
Hình 51: Thông báo từ messagebox khi đã xử lý các giá trị Duplicate trước đó.....	49
Hình 52: Thông báo từ messagebox khi lựa chọn chuẩn hóa kiểu dữ liệu.....	50
Hình 53: Thông báo từ messagebox khi chuẩn hóa kiểu dữ liệu hoàn tất.....	50
Hình 54: Thông báo từ messagebox khi lựa chọn chuẩn hóa DataFrame.....	50
Hình 55: Thông báo từ messagebox khi chuẩn hóa DataFrame hoàn tất.....	51
Hình 56: Mô tả minh họa thông báo hiển thị các kiểu dữ liệu của Dataframe.....	51
Hình 57: Giao diện nhóm chức năng CRUD.....	51
Hình 58: Messagebox thông báo khi thao tác tìm kiếm không tìm thấy giá trị show_id cần cập nhật dữ liệu.....	52
Hình 59: Hình ảnh ô nhập tự động điền giá trị hiện tại khi tìm thấy giá trị show_id.....	52
Hình 60: Hình ảnh thông báo cập nhật dữ liệu thành công.....	53
Hình 61: Tiến hành chọn các dòng cần xóa dữ liệu.....	53
Hình 62: Hình ảnh thông báo cập xóa dữ liệu thành công.....	53
Hình 63: Hình ảnh giao diện nhập thông tin cho dòng Record mới.....	54
Hình 64: Hình ảnh thông báo lỗi khi người dùng nhập sai định dạng cho Record mới.....	54
Hình 65: Hình ảnh thông báo sau khi thêm dữ liệu thành công.....	55
Hình 66: Hình ảnh chức năng sắp xếp trên giao diện UI.....	55
Hình 67: Hình ảnh chức năng tìm kiếm trên giao diện UI.....	56
Hình 68: Giao diện nhóm chức năng ACTIVITY.....	56
Hình 69: Thông báo messagebox từ nút lệnh Data Analyzing.....	56
Hình 70: Thông báo messagebox từ nút lệnh Data Overview.....	57
Hình 71: Minh họa giao diện một vài biểu đồ mẫu.....	58
Hình 72: Hình ảnh giao diện nhóm chức năng VISUALIZATION DATA.....	58

PHẦN 1: MỞ ĐẦU

1.1 Tính cấp thiết của đề tài

Trong bối cảnh số hóa hiện nay cùng với sự phát triển mạnh mẽ của ngành công nghiệp giải trí trực tuyến, Netflix đã trở thành một trong những nền tảng phát trực tuyến hàng đầu thế giới, với hàng trăm triệu người dùng trên toàn cầu. Sự bùng nổ của ngành công nghiệp này đòi hỏi việc hiểu rõ các xu hướng, sở thích và hành vi của người dùng để duy trì tính cạnh tranh và đáp ứng nhu cầu thị trường. Chính vì vậy, việc phân tích dữ liệu của hệ thống phim sẽ giúp Netflix hiểu rõ hơn về xu hướng, sở thích và hành vi người dùng, từ đó cá nhân hóa trải nghiệm và cải thiện chất lượng dịch vụ.

Bên cạnh đó, Netflix sẽ phải đối mặt với các đối thủ như Disney+, Amazon Prime, HBO Max,... đang phát triển mạnh mẽ, làm gia tăng áp lực cạnh tranh giữa những nền tảng phát trực tuyến. Việc khai thác dữ liệu một cách hiệu quả sẽ giúp Netflix duy trì lợi thế cạnh tranh và định hình chiến lược phát triển trong tương lai. Netflix sở hữu một lượng dữ liệu khổng lồ về danh mục phim, series, đánh giá, lịch sử xem của người dùng và nhiều yếu tố khác. Phân tích dữ liệu này không chỉ cung cấp những thông tin chi tiết quý giá để tối ưu hóa nội dung và cải thiện trải nghiệm người dùng mà còn giúp đưa ra các quyết định kinh doanh chiến lược.

Hơn nữa, việc phân tích dữ liệu còn mở ra cơ hội cho Netflix trong việc phát triển nội dung gốc dựa trên những xu hướng và sở thích cụ thể của khán giả. Điều này không chỉ gia tăng tính cạnh tranh mà còn tạo ra sự khác biệt trong danh mục nội dung mà Netflix cung cấp, từ đó thu hút thêm người dùng mới. Ngoài ra, việc kết hợp phân tích dữ liệu với công nghệ trí tuệ nhân tạo có thể giúp Netflix dự đoán những xu hướng mới và phát triển các sản phẩm sáng tạo, phù hợp với thị hiếu của người xem.

Cuối cùng, nghiên cứu và ứng dụng phân tích dữ liệu cũng có thể mang lại giá trị lớn trong việc xây dựng cộng đồng người dùng trung thành. Khi Netflix hiểu rõ hơn về nhu cầu và mong đợi của khán giả, họ có thể tạo ra các chương trình sự kiện trực tuyến hoặc nội dung tương tác, góp phần nâng cao trải nghiệm người xem và khuyến khích sự tham gia của cộng đồng. Từ đó cho thấy việc phân tích dữ liệu không chỉ

giúp Netflix nâng cao năng lực cạnh tranh mà còn định hình tương lai của ngành công nghiệp giải trí trực tuyến.

1.2 Mục tiêu nghiên cứu

Mục tiêu của đề tài “**Phân tích dữ liệu hệ thống phim trên Netflix**” là xây dựng ứng dụng hỗ trợ làm sạch, phân loại và quản lý dữ liệu từ nền tảng Netflix. Ứng dụng sẽ tích hợp các chức năng như thêm, xóa, cập nhật, phân tích và hiển thị số liệu qua biểu đồ trực quan. Đồng thời, phát triển giao diện đồ họa (GUI) thân thiện, dễ sử dụng, giúp người dùng tương tác hiệu quả và khai thác dữ liệu một cách tối ưu.

1.3 Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu:

Đối tượng nghiên cứu của đề tài là dữ liệu hệ thống phim trên nền tảng Netflix, bao gồm các thông tin như danh mục phim và series, thể loại, năm phát hành, lượt đánh giá, lượt xem của khách hàng, và các yếu tố liên quan đến hành vi người dùng.

Phạm vi nghiên cứu:

- Nghiên cứu tập trung vào dữ liệu kho phim của Netflix
- Phân tích dữ liệu: Tiến hành phân tích, khai thác, xử lý dữ liệu từ hệ thống phim trên nền tảng Netflix.

PHẦN 2: NỘI DUNG

CHƯƠNG 1: TÓM TẮT CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về lý thuyết

2.1.1 Thư viện Pandas

Thư viện Pandas trong Python là một thư viện mã nguồn mở mạnh mẽ, được sử dụng phổ biến để làm việc với và xử lý dữ liệu. Pandas cung cấp một loạt các công cụ và cấu trúc dữ liệu, chủ yếu là DataFrame, để thực hiện các nhiệm vụ phân tích và xử lý dữ liệu dễ dàng hơn trong Python. Thư viện này đặc biệt phù hợp cho các công việc liên quan đến khoa học dữ liệu và phân tích dữ liệu.

Tại sao nên sử dụng thư viện Pandas?

- **DataFrame:** Pandas giới thiệu một cấu trúc dữ liệu gọi là DataFrame, giúp bạn làm việc linh hoạt và hiệu quả với dữ liệu có cấu trúc.

- **Đọc/Ghi Dữ Liệu:** Pandas cho phép bạn đọc và ghi dữ liệu từ/to nhiều định dạng tệp như CSV, văn bản, Excel và cơ sở dữ liệu SQL, HDF5, và nhiều định dạng khác.

- **Xử Lý Dữ Liệu Thiếu:** Nó cung cấp các công cụ thông minh để xử lý dữ liệu thiếu và tự động chuyển đổi dữ liệu không có cấu trúc thành dạng có cấu trúc.

- **Chỉnh Sửa Cấu Trúc Dữ Liệu:** Bạn có thể dễ dàng thay đổi cấu trúc của dữ liệu, thêm/xóa cột dữ liệu và thực hiện các phép biến đổi dữ liệu khác.

- **Group By:** Pandas cho phép bạn tổng hợp và biến đổi dữ liệu bằng cách sử dụng group by, giúp bạn thực hiện các phép toán trên các tập dữ liệu.

- **Trộn và Kết Hợp:** Bạn có thể kết hợp các tập dữ liệu khác nhau dựa trên các cột hoặc chỉ mục chung một cách dễ dàng.

- **Chỉ Mục Dữ Liệu:** Pandas cho phép bạn chỉ mục dữ liệu theo nhiều chiều, giúp bạn thực hiện các phép toán giữa dữ liệu có nhiều chiều và dữ liệu có ít chiều.

- **Hiệu Năng:** Thư viện Pandas được tối ưu hóa về hiệu năng cho việc làm việc với dữ liệu lớn.

2.1.2 Thư viện Numpy

NumPy (Numerical Python) là một thư viện Python mã nguồn mở được sử dụng trong hầu hết các lĩnh vực khoa học và kỹ thuật. Đây là tiêu chuẩn chung để làm việc với dữ liệu số bằng Python và là tiêu chuẩn cốt lõi của hệ sinh thái Python và PyData. NumPy API được sử dụng rộng rãi trong Pandas, SciPy, Matplotlib, scikit-learning, scikit-image và hầu hết các gói Python khoa học và khoa học dữ liệu khác.

Thư viện NumPy chứa các cấu trúc dữ liệu ma trận và mảng đa chiều (bạn sẽ tìm thấy thêm thông tin về điều này trong các phần sau). NumPy có thể được sử dụng để thực hiện nhiều phép toán khác nhau trên mảng. Nó bổ sung các cấu trúc dữ liệu mạnh mẽ vào Python để đảm bảo tính toán hiệu quả với các mảng và ma trận, đồng thời nó cung cấp một thư viện khổng lồ các hàm toán học cấp cao hoạt động trên các mảng và ma trận này.

Vì sao nên sử dụng NumPy?

NumPy cung cấp cho bạn rất nhiều cách nhanh chóng và hiệu quả để tạo mảng (array) và thao tác dữ liệu số bên trong chúng. list có thể chứa các kiểu dữ liệu khác nhau, còn tất cả các phần tử trong array NumPy phải đồng nhất. Điều này cho phép các phép toán được thực hiện trên mảng sẽ cực kỳ kém hiệu quả nếu các mảng không đồng nhất. Cũng bởi vì thế, 1 array tiêu tốn ít bộ nhớ hơn, dẫn đến NumPy sử dụng ít bộ nhớ hơn nhiều để lưu trữ dữ liệu và nó cung cấp một cơ chế xác định các kiểu dữ liệu. Điều này cho phép mã được tối ưu hóa hơn nữa.

2.1.3 Thư viện Matplotlib

Matplotlib là một thư viện phổ biến trong Python, được sử dụng để trực quan hóa dữ liệu. Đây là một thư viện đa nền tảng, cho phép tạo ra các đồ thị 2D từ dữ liệu trong các mảng. Matplotlib được viết bằng Python và sử dụng NumPy, phần mở rộng toán học của Python.

Các thành phần chính của Matplotlib:

- **Figure:** Là khung chứa tất cả những gì bạn sẽ vẽ trên đó.
- **Axes:** Là thành phần chính của một figure, nơi các đồ thị được vẽ lên.
- **Axis:** Là các dòng số giống như các đối tượng và đảm nhiệm việc tạo các giới hạn biểu đồ.

- **Artist:** Mọi thứ mà bạn có thể nhìn thấy trên figure là một artist, như Text objects, Line2D objects, collection objects.

Các loại biểu đồ phổ biến:

- **Biểu đồ đường:** Được sử dụng để hiển thị dữ liệu liên tục.

- **Biểu đồ cột:** Được sử dụng để hiển thị dữ liệu phân loại.

- **Biểu đồ tròn:** Được sử dụng để hiển thị tỷ lệ phần trăm của các phần tử trong tổng thể.

- **Biểu đồ phân tán:** Được sử dụng để hiển thị mối quan hệ giữa hai biến số.

2.1.4 Thư viện Tkinter

Tkinter là một thư viện trong ngôn ngữ lập trình Python được sử dụng để tạo giao diện đồ họa người dùng (GUI). "Tkinter" là viết tắt của "Tk interface", một toolkit đồ họa cung cấp các công cụ để phát triển giao diện người dùng.

Tkinter là một phần của thư viện tiêu chuẩn của Python và đã được tích hợp sẵn trong hầu hết các cài đặt Python. Điều này giúp cho Tkinter trở thành một lựa chọn phổ biến cho việc phát triển ứng dụng với giao diện đồ họa đơn giản trong Python.

Một số đặc điểm của Tkinter bao gồm khả năng tạo các thành phần giao diện như cửa sổ, nút, ô văn bản, và các widget khác để tương tác với người dùng. Tkinter cung cấp cả các sự kiện và phương thức để xử lý tương tác người dùng và thay đổi trạng thái của ứng dụng.

CHƯƠNG 2: GIAI ĐOẠN PHÂN TÍCH VÀ XÂY DỰNG

2.1 Thu thập dữ liệu

2.1.1 Mô tả nguồn dữ liệu

- **Tên nguồn dữ liệu:** Netflix Movies and TV Shows

- **Lịch sử và nguồn gốc:** Được tải từ *Kaggle*, do người dùng Shivam Bansal cung cấp. Nguồn thông tin được thu thập từ thư viện công khai của Netflix tính đến tháng 7 năm 2021.

- **Kích thước:** ~3.4MB, bao gồm 8807 bản ghi và 12 cột.

- **Định dạng:** CSV.

- **Công Dụng:** Dữ liệu có thể được sử dụng để phân tích các xu hướng trên nền tảng Netflix, như thể loại phim phổ biến, quốc gia sản xuất, và sự phát triển theo thời gian của các bộ phim và chương trình truyền hình.

- **Mục đích:**

+ Phục vụ các nghiên cứu và phân tích về xu hướng phim và chương trình truyền hình, và giúp người dùng tìm hiểu thị trường giải trí trên Netflix.

+ Có thể ứng dụng trong việc học các kỹ năng khoa học dữ liệu, phân tích dữ liệu, hoặc xây dựng các mô hình dự đoán cho nền tảng giải trí.

- **Phạm vi thời gian:**

+ Tập dữ liệu bao gồm các nội dung được phát hành từ năm 1925 đến năm 2021 (năm phát hành của nội dung).

+ Dữ liệu cũng ghi lại ngày tháng mà nội dung được thêm vào Netflix (từ 2008 đến 2021).

- **Tần suất cập nhật:** Đây là tập dữ liệu tĩnh và không được cập nhật thường xuyên.

- **Ngôn ngữ:** Nội dung mô tả và thông tin đều bằng tiếng Anh.

- **Tính chính xác:** Dữ liệu đáng tin cậy vì được tổng hợp từ thông tin chính thức của Netflix.

- Mô tả chi tiết các cột:

- + **show_id (String):** ID duy nhất cho mỗi phim hoặc chương trình truyền hình.
- + **type (String):** Loại nội dung: "Movie" (phim) hoặc "TV Show" (chương trình truyền hình).
- + **Title (String):** Tên phim hoặc chương trình truyền hình.
- + **Director (String):** Tên đạo diễn (nếu có).
- + **Cast (String):** Danh sách các diễn viên chính.
- + **Country (String):** Quốc gia sản xuất.
- + **date_added (Date):** Ngày nội dung được thêm vào Netflix.
- + **release_year (Int):** Năm phát hành nội dung.
- + **Rating (String):** Xếp hạng độ tuổi (ví dụ: PG, TV-MA, G).
- + **Duration (String):** Độ dài của phim (phút) hoặc số mùa của chương trình truyền hình.
- + **listed_in (String):** Thể loại của nội dung (ví dụ: Drama, Comedy).
- + **Description (String):** Mô tả ngắn về nội dung.

Hạn chế và khiếm khuyết:

- Một số phim thiếu thông tin về đạo diễn hoặc diễn viên, một số cột dữ liệu bị lỗi hoặc không có.
- Không có thông tin về lượt xem hoặc mức độ phổ biến của từng nội dung.
- Dữ liệu không được cập nhật thường xuyên, vì vậy có thể không phản ánh đầy đủ nội dung Netflix hiện tại.

2.1.2 Chi tiết tệp dữ liệu

- Class OverviewData

Giai đoạn này là một giai đoạn quan trọng trong quá trình phân tích dữ liệu, nhằm giúp hiểu rõ hơn về các nguồn dữ liệu, cấu trúc và tính chất của chúng. Qua đó,

tạo cơ sở để bước đến những giai đoạn tiếp theo trong quá trình phân tích dữ liệu một cách thuận lợi hơn.

- Sơ lược về các bước tổng quan hóa dữ liệu trên tập dữ liệu:

- + Xem tổng quan về kiểu dữ liệu các cột trong DataFrame.
- + Xem kích thước dữ liệu (số cột, số dòng) trong DataFrame.
- + Xem qua các giá trị xuất hiện nhiều nhất trong các cột ('type', 'country', 'director') trong DataFrame.
- + Xem thông tin tổng quan về DataFrame (số lượng null và kiểu dữ liệu của từng cột).

- Xem tổng quan về kiểu dữ liệu các cột trong DataFrame.

Ở bước này, ta gọi hàm `get_dtypes()`:

Ta sử dụng thuộc tính `.dtypes` của DataFrame để lấy kiểu dữ liệu của từng cột.

Kết quả sẽ là một Series, trong đó chỉ mục là tên của các cột và giá trị là kiểu dữ liệu tương ứng (ví dụ: int64, float64, object, v.v.) giúp người dùng dễ dàng xem xét và hiểu cấu trúc dữ liệu

```
[5 rows x 12 columns]
===== Kiểu dữ liệu =====
show_id      object
type         object
title        object
director     object
cast         object
country      object
date_added   object
release_year  int64
rating       object
duration     object
listed_in    object
description  object
dtype: object
```

Hình 1: Mô tả kiểu dữ liệu in ra màn hình

- Xem kích thước dữ liệu (số cột, số dòng) trong DataFrame.

Kết quả khi thực hiện hàm xem kích thước dữ liệu trong DataFrame:

```
Số lượng dòng: 8807
Số lượng cột: 12
```

Hình 2: Kết quả khi thực hiện in ra từ hàm `get_shape()`

Với số lượng 8807 dòng trong DataFrame đã cung cấp một lượng lớn dữ liệu cho việc phân tích các xu hướng của người xem. Đồng thời, số lượng cột cho thấy sự đa dạng trong các thuộc tính của nội dung, giúp người dùng dễ dàng thực hiện các phân tích sâu hơn về sở thích của người xem và hiệu suất của các nội dung khác nhau.

Xem qua các giá trị xuất hiện nhiều nhất trong các cột ('type', 'country', 'director') trong DataFrame

Để có thể tạo cơ sở thuận lợi cho việc phân tích dữ liệu người xem ta có thể xem qua về các giá trị xuất hiện nhiều nhất trong các cột ('type', 'country', 'director') trong DataFrame thông qua hàm `most_frequent_values` với các phương thức:

`value_counts()`: Phương thức này đếm số lần xuất hiện của từng giá trị trong cột, trả về một Series với các giá trị và số lần xuất hiện của chúng, sắp xếp theo thứ tự giảm dần.

`idxmax()`: Phương thức này trả về giá trị có số lần xuất hiện nhiều nhất (tức là chỉ số của giá trị lớn nhất trong Series).

`max()`: Phương thức này trả về giá trị lớn nhất trong Series được tạo ra bởi `value_counts()`, hay số lần xuất hiện nhiều nhất của giá trị trong cột.

Kết quả khi thực hiện hàm:

```
Giá trị xuất hiện nhiều nhất trong cột 'type': Movie
Số lần xuất hiện: 6131

Giá trị xuất hiện nhiều nhất trong cột 'country': United States
Số lần xuất hiện: 2818

Giá trị xuất hiện nhiều nhất trong cột 'director': Rajiv Chilaka
Số lần xuất hiện: 19
```

Hình 3: Kết quả in ra của hàm `most_frequent_values()`

Xem thông tin tổng quan về DataFrame (số lượng null và kiểu dữ liệu của từng cột)

Để có một cái nhìn tổng quan hơn về DataFrame ta có thể sử dụng phương thức `info()` - một phương thức của DataFrame trong Pandas. Nó cung cấp thông tin chi tiết về DataFrame (số lượng hàng và cột, kiểu dữ liệu của từng cột, số lượng giá trị không null trong mỗi cột, dung lượng bộ nhớ sử dụng) thông qua hàm `get_overview()` :

Kết quả khi thực hiện hàm:

```
Thông tin tổng quan về dữ liệu:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8807 entries, 0 to 8806
Data columns (total 12 columns):
#   Column          Non-Null Count  Dtype
---  -
0   show_id         8807 non-null   object
1   type            8807 non-null   object
2   title           8807 non-null   object
3   director        6173 non-null   object
4   cast            7982 non-null   object
5   country         7976 non-null   object
6   date_added      8797 non-null   object
7   release_year    8807 non-null   int64
8   rating          8803 non-null   object
9   duration        8804 non-null   object
10  listed_in       8807 non-null   object
11  description     8807 non-null   object
dtypes: int64(1), object(11)
memory usage: 825.8+ KB
```

Hình 4: Kết quả trả về in ra từ hàm `get_overview()`

2.2 Làm sạch dữ liệu

Class DataCleaning:

Thông qua quá trình thực hiện thu thập dữ liệu (data crawling), các nguồn dữ liệu khi được tập hợp vào file csv sẽ đôi lúc gặp lỗi (nhận dạng, thông tin bị trống, trùng lặp...) bước tiếp theo là xử lý và làm sạch nguồn dữ liệu. Nhìn vào tổng quát tệp dữ liệu, ta thấy có những record chứa giá trị null, chứa giá trị trùng lặp hay chưa thống nhất về kiểu dữ liệu.

635	s634	Movie	Into the Wind	Soňa Šustková	Vladimír Polivka, Jelenovfa Boková, Matyáš Reznicek	26-Jun-21	2018 TV-MA	76 min	Dramas, Ind Two siblings set sail as
636	s635	Movie	Wonder Boy	Anissa Bonnefont	Olivier Rousteing	26-Jun-21	2019 TV-14	83 min	Documenta This revealing documen
637	s635	Movie	Wonder Boy	Anissa Bonnefont	Olivier Rousteing	26-Jun-21	2019 TV-14	83 min	Documenta This revealing documen

Hình 5 : Các record chứa giá trị trùng lặp trong tập dữ liệu

642	s640	TV Show	Godzilla Singular Point		Yume Miyamoto, Shoya Ishige, Misaki Kuno, Rie Kuwamizu, Taro Kuchi, W	24-Jun-21	2021 TV-14	1 Season	Anime Serie Brought together by a i
643	s641	TV Show	Jina!		Nexxolo Dlamini, Candice Modiselle, Sne Mbathe, Stella Dlangalala, Zazi K	24-Jun-21	2021 TV-MA	1 Season	International A talented street dance

Hình 6 : Các record chứa giá trị NULL trong tập dữ liệu

Sơ lược các bước làm sạch dữ liệu của tập dữ liệu:

- + Xử lý giá trị null
- + Xử lý giá trị trùng lặp
- + Chuyển hóa cột date_added thành kiểu datetime
- + Xử lý dữ liệu cột “title”
- + Xóa các kí tự đặc biệt của trong cột “title”

2.2.1 Xử lý giá trị null

Các thông tin khi được thêm vào tập dữ liệu nếu thiếu thông tin trong cột sẽ tạo ra giá trị null (để trống). Một trường với một giá trị NULL là một trường không có giá trị. Một giá trị NULL thì khác với một giá trị “0” hoặc một trường chứa khoảng trắng. Một trường với một giá trị NULL là trường đã bị bỏ trống trong quá trình tạo bản ghi.

Nhìn vào tập dữ liệu, ta có thể thấy giá trị null xuất hiện rải rác trong các columns, có thể dẫn đến sai số trong quá trình phân tích dữ liệu. Chủ yếu các giá trị null xuất hiện trong cột “director” và “cast”, vốn là các trường có kiểu dữ liệu string và gồm nhiều phân tử (gồm nhiều đạo diễn, diễn viên trong một bộ phim) và mang tính sự thật. Vì thế, hướng giải quyết khách quan nhất trong trường hợp này là loại bỏ các record bị thiếu giá trị để đảm bảo tính chính xác. Trong source code, để tìm và xóa các giá trị null, ta có thể sử dụng hàm isnull() trong thư viện pandas để kiểm tra giá trị null. Sau đó loại bỏ các record đó thông qua hàm dropna()

Function showNull():

Hàm để tìm và hiển thị ra các record chứa giá trị null ở các cột. Biến `null_count` sử dụng hàm `isnull()` và `sum()` để kiểm tra giá trị null và đếm các record. Kết quả khi thực hiện hàm:

```
-----Checking Null-----
dataframe có chứa giá trị null
Có 4308 giá trị null:
show_id      0
type         1
title        0
director    2634
cast        825
country     831
date_added   10
release_year  0
rating       4
duration     3
listed_in    0
description  0
dtype: int64
các dòng chứa giá trị null:
   show_id ... description
0      s1 ... As her father nears the end of his life, filmm...
1      s2 ... After crossing paths at a party, a Cape Town t...
2      s3 ... To protect his family from a powerful drug lor...
3      s4 ... Feuds, flirtations and toilet talk go down amo...
4      s5 ... In a city of coaching centers known to train I...
...     ... ...
8796  s8796 ... Now that he's discovered the Pendulum Summonin...
8797  s8797 ... During the Mongol invasions, Yunus Emre leaves...
8798  s8798 ... Teen surfer Zak Storm is mysteriously transpor...
8801  s8801 ... Strong-willed, middle-class Kashaf and carefre...
8804  s8804 ... While living alone in a spooky town, a young g...
[3476 rows x 12 columns]
```

Hình 7: Hiển thị các giá trị Null ra ngoài màn hình Console

Hàm sẽ trả về trạng thái dataframe có chứa giá trị null hay không, số lượng giá trị null ở từng column và các dòng chứa giá trị null.

Function `removeNull()`:

Hàm để xóa các record chứa các giá trị null đã tìm được. Sử dụng biến `initial_count` và `final_count` để xác định số giá trị đã xóa. Sử dụng `dropna (axis=0)` để xóa theo hàng. Kết quả khi thực hiện hàm:

```
đã xóa 3476 records trùng.
```

Hình 8: Mô tả xuất ra màn hình khi xóa các giá trị NULL

Hàm sẽ trả về số record đã xóa.

2.2.2 Xử lý giá trị duplicated

Trong quá trình thu thập thông tin cũng có thể xảy ra vấn đề các giá trị trùng lặp được thu thập vào tệp dữ liệu do được thu thập từ nhiều nguồn khác nhau. Giá trị duplicated có thể là 1 record hay chỉ 1 column tùy theo cách xử lý. Duplicate có thể khiến cho tệp dữ liệu dư thừa và ảnh hưởng đến sự chính xác trong quá trình phân tích. Trong tệp dữ liệu này, duplicate sẽ được coi là các record có các giá trị hoàn toàn giống nhau.

Trong tệp dữ liệu ban đầu, rất khó để xác định xem có bao nhiêu record đang bị trùng lặp. Để xác định điều này ta cần xây dựng hàm để đếm các record bị trùng. Theo kết quả hàm showDup() bên trong source code, tệp dữ liệu chỉ chứa 2 record bị trùng lặp, đảm bảo chất lượng của tệp dữ liệu. Sau khi xác định có tồn tại giá trị duplicated, ta thực hiện xóa giá trị thứ hai trong hai record bị trùng để đảm bảo dữ liệu không bị sót và độc nhất. Trong source code, để tìm và xóa các giá trị duplicated, ta có thể sử dụng hàm duplicated() trả về 1 dataframe con chứa các giá trị duplicated và hàm drop_duplicates() để xóa các giá trị trùng.

Function showDup():

Hàm để tìm và hiển thị các dòng dữ liệu bị trùng lặp, sử dụng hàm duplicated() được tích hợp sẵn trong pandas trả về Series boolean, sau đó sử dụng dataframe để lưu như một index để trả về những dòng dữ liệu bị lặp. Biến duplicate_count để đếm các dòng dữ liệu lặp thông qua hàm sum(). Kết quả khi thực hiện hàm:

```
-----Checking Duplicate-----
số dòng trùng: 2
dòng dữ liệu bị trùng:
   show_id  ... description
635    s635  ... This revealing documentary follows Balmain cre...
[1 rows x 12 columns]
```

Hình 9: Mô tả xuất ra màn hình từ hàm showDup()

Hàm sẽ trả về số dòng dữ liệu trùng và thông tin dòng dữ liệu bị trùng

Fucntion deleteDup():

Hàm để thực hiện loại bỏ các dòng dữ liệu bị trùng, sử dụng hàm `drop_duplicates()` trong pandas để loại bỏ các dòng dữ liệu, ở chế độ “first” để giữ lại bản ghi đầu tiên. Biến `initial_count` và `final_count` để đếm số record đã xóa. Kết quả khi thực hiện hàm:

```
đã xóa 1 records trùng.
```

Hình 10: Mô tả xuất ra màn hình từ hàm `deleteDup()`

Hiện thị thông báo đã xóa bao nhiêu dòng dữ liệu trùng

2.2.3 Chuẩn hóa kiểu dữ liệu

Trước khi đi vào phân tích, cần kiểm tra các kiểu dữ liệu của từng cột nhằm không gây ra lỗi. Chuẩn hóa kiểu dữ liệu đưa các cột về các kiểu dữ liệu mong muốn. Trong tệp dữ liệu này ta có thể thống kê qua các kiểu dữ liệu của từng thông qua dòng code: `print(df.dtypes)`

```
----- Kiểu dữ liệu dataframe -----
show_id      object
type         object
title        object
director     object
cast         object
country      object
date_added   object
release_year  int64
rating       object
duration     object
listed_in    object
description   object
dtype: object
```

Hình 11: Mô tả xuất ra màn hình kiểu dữ liệu từ `DataFrame`

Kết quả ta thấy tất cả đều có kiểu dữ liệu object (string) ngoại trừ cột `release_year`. Ta thấy có vấn đề khi cột “date_added” là thời gian được thêm vào nền tảng Netflix, vốn phải là kiểu dữ liệu `datetime`:

April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
April 1, 2021
31-Mar-21
31-Mar-21
31-Mar-21
31-Mar-21
31-Mar-21
30-Mar-21
30-Mar-21
30-Mar-21
30-Mar-21
30-Mar-21

Hình 12: Một số dòng Record ban đầu chưa được làm sạch từ cột date_added

Vì vậy ta cần chuyển kiểu dữ liệu cho cột date_added thành kiểu datetime. Cột “duration” phản ánh độ dài nếu ở kiểu dữ liệu string cũng sẽ gây khó khăn trong việc phân tích dữ liệu. Trong source code ta có thể sử dụng hàm to_datetime() trong thư viện pandas để chuyển đổi kiểu dữ liệu.

Function to_datetime():

Để chuyển hóa kiểu dữ liệu, ta sử dụng hàm to_datetime() được tích hợp sẵn trong pandas. Do trong tệp dữ liệu gốc, data đang được lưu ở nhiều dạng khác nhau nên ta sử dụng mode format là “mixed”. Data sẽ chuyển về kiểu dữ liệu datetime với định dạng mm/dd/yyyy.

Trong tệp dữ liệu cột “date_added” sẽ trở thành như sau:

G
date_added
9/24/2021
9/24/2021
9/24/2021
9/23/2021
9/21/2021
9/20/2021
9/19/2021
9/19/2021
9/16/2021
9/16/2021
9/16/2021
9/16/2021
9/16/2021
9/16/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021
9/15/2021

Hình 13: Dữ liệu cột `date_added` sau khi thực hiện hàm `to_datetime()`

Có hai loại hình phim được thống kê ở đây đó là “TV Show” và “Movie”, với “TV Show” sẽ có đơn vị “Seasons”, còn “Movie” sẽ có đơn vị “min” (phút). Vấn đề với việc một cột có hai đơn vị đo lường thời gian sẽ gây nên bất trắc cho quá trình phân tích dữ liệu. Việc phân tách ra làm hai cột riêng biệt với kiểu dữ liệu integer ứng với từng giá trị của cột “type” (loại hình “Movie” hoặc “TV Show”) sẽ dễ dàng hơn cho việc tổng hợp và thống kê.

Function `split_duration()`:

Để tách cột “duration” làm hai cột mới là cột “minutes” cho thời lượng phim loại “Movie” và cột “season” cho thời lượng mùa loại “TV Show”, ta sử dụng hàm `apply()` áp dụng biểu thức lambda trả về giá trị thời lượng của cột “duration” tương ứng với 2 cột mới, cột còn lại mang giá trị 0. Sau đó ép giá trị về kiểu integer và lưu vào trong cột mới. Sau khi thực hiện kết quả in ra màn hình:

```

----- Tách cột duration -----
0      90
1       0
2       0
3       0
4       0
...
8803   158
8804    0
8805    88
8806    88
8807   111
Name: minutes, Length: 8808, dtype: int64
0       0
1       2
2       1
3       1
4       2
..
8803    0
8804    2
8805    0
8806    0
8807    0
Name: season, Length: 8808, dtype: int64

```

Hình 14: Mô tả xuất ra màn hình console của hàm `split_duration()`

```

----- Kiểu dữ liệu dataframe -----
show_id      object
type         object
title        object
director     object
cast         object
country      object
date_added   datetime64[ns]
release_year int64
rating       object
duration     object
listed_in    object
description  object
minutes      int64
season       int64

```

Hình 15: Mô tả xuất ra màn hình Console kiểu dữ liệu của `Dataframe`

Có thể thấy cột `date_added` đã được chuyển về kiểu dữ liệu `datetime` và xuất hiện hai cột mới là “minutes” và “season” mang kiểu dữ liệu integer.

2.2.4 Chuẩn hóa Dataframe

Sau khi thực hiện các công đoạn làm sạch cơ bản, ta cần đi tìm những lỗi sai có thể gây bug trong tệp dữ liệu. Đầu tiên khi nhìn vào tên các column, cột “listed_in” có thể gây hiểu nhầm vì không bao hàm được hết ý nội dung của column. Nội dung của cột chính là thể loại của các movie, tv show.

K
listed_in
Documentaries
International TV Shows, TV Dramas, TV Mysteries
Crime TV Shows, International TV Shows, TV Action & Adventure
Docuseries, Reality TV
International TV Shows, Romantic TV Shows, TV Comedies
TV Dramas, TV Horror, TV Mysteries
Children & Family Movies
Dramas, Independent Movies, International Movies
British TV Shows, Reality TV
Comedies, Dramas
Crime TV Shows, Docuseries, International TV Shows

Hình 16: Cột “listed_in” trong tệp dữ liệu gốc

Ta cần đổi tên thành “genres” nhằm mục đích dễ hiểu.

Vấn đề thứ 2, khi dò tìm các giá trị trong cột “title”, ta có thể thấy một số record gặp vấn đề về định dạng và kí tự:

	7:19
	23:59
	9
	21
	46
	122
	187
	678
	706
	1920
	1922
	1983
	1994
	2012
	2,215
	3022
	9-Feb
	9-Feb
	22-Jul
	22-Jul
	15-Aug
	15-Aug
	1-Oct
#Alive	
#AnneFrank - Parallel Stories	
#blackAF	
???	???
??? ?????	
??? ?????	
????	
????	
???? ???? : ??? ??	
???? ???????	
??????	
????????	
????????	
????????????????	
??Kuch Bheege Alfaaz	
?Goli Soda 2	

Hình 17: Một số record gặp vấn đề về định dạng và kí tự trong tập dữ liệu gốc

Ta cần giải quyết các vấn đề định dạng này để tránh tạo ra thống kê không minh bạch. Đầu tiên, ta thấy có những dòng record đang ở dạng ngày tháng. Sau đó có một vài record chứa các kí tự '#' hay '?' ở đầu dòng, và một vài dòng chứa các kí tự bị lỗi đã bị chuyển thành dấu '?'. Ta cần loại bỏ các record chứa các giá trị lỗi. (lưu ý các tên phim ở định dạng số và giờ vẫn là tên phim hợp lệ). Đối với giá trị chứa dấu '#' ở đầu, ta chỉ việc loại bỏ đi kí tự '#'.

Function Normalize_title():

Để loại bỏ các giá trị không phải kiểu str, ta sử dụng hàm lambda trả về các giá trị trong column không thuộc kiểu str qua hàm isinstance() và lưu kiểu index. Để xóa các giá trị datetime có format %d-%m (day-month), ta sử dụng hàm str.match để kiểm tra các chuỗi có khớp với định dạng và lưu kiểu index. Sau đó sử dụng hàm drop() các index để loại bỏ record. Sử dụng hàm strip() và title() để xóa các khoảng trắng thừa trong chuỗi.

Function delete_strange_symbol():

Để loại bỏ các kí tự thừa, kí tự lỗi, đầu tiên ta xử lý các giá trị lỗi bị biến thành các dấu '?'. Kiểm tra nếu chuỗi có hai dấu '?' liên nhau thì xóa, sử dụng hàm contains() để xử lý và lưu dạng index. Tiếp đến xử lý các kí tự đầu câu không mong muốn, ta sử dụng hàm startswith() và áp dụng biểu thức lambda kiểm tra, tìm các kí tự bắt đầu bằng kí tự '#' hay '?' và chỉ loại bỏ các kí tự không mong muốn. Sau đó sử dụng hàm isdigit() để loại bỏ các tên phim lỗi là số.

Sau khi thực hiện hai functions, cột "title" trở thành":

Alive
Annefrank - Parallel Stories
Friendbutmarried
Friendbutmarried 2
Realityhigh
Roxy
Selfie
Selfie 69
Goli Soda 2
Mayurakshi
¡Ay, Mi Madre!
1 Chance 2 Dance
1 Mile To You
10 Days In Sun City
10 Jours En Or
10,000 B.C.
100 Meters
100% Halal
1000 Rupee Note
12 Round Gun
13 Cameras
13 Sins
14 Blades
14 Cameras
16 Blocks
17 Again
18 Presents

Hình 18: Kết quả thay đổi sau khi thực hiện các function chuẩn hóa Dataframe

Kết thúc quy trình làm sạch dữ liệu, dữ liệu đã được làm sạch để chuẩn bị cho thống kê và phân tích dữ liệu:

- Loại bỏ các giá trị Null
- Loại bỏ các giá trị Duplicated
- Chuyển đổi kiểu dữ liệu cột “date_added” thành datetime
- Đổi tên cột “listed_in” thành “genres”
- Loại bỏ và sửa các kí tự lỗi trong cột “title”

2.3. CRUD

Class CRUD

Lớp CRUD cung cấp một cách tiếp cận rõ ràng và hiệu quả để quản lý dữ liệu trong pandas DataFrame. Nó cho phép người dùng thực hiện các thao tác thêm, cập nhật, xóa một cách dễ dàng, đồng thời xử lý các trường hợp ngoại lệ như kiểm tra sự tồn tại của ID trước khi thêm, cập nhật hoặc xóa.

Sơ lược về cơ chế CRUD:

- + Thêm dòng mới vào DataFrame.
- + Đọc DataFrame.
- + Cập nhật thông tin của một dòng trong DataFrame.
- + Xóa một dòng khỏi DataFrame.

2.3.1 Thêm dòng mới vào DataFrame

Cơ chế Create trong CRUD cho phép người dùng dễ dàng mở rộng DataFrame bằng cách thêm một hay nhiều row mới vào DataFrame nhằm hỗ trợ tốt hơn cho việc phân tích dữ liệu.

Ở hàm `create_data(new_data)` ta sử dụng `.loc` của DataFrame để thêm vào một dòng mới. Bên cạnh đó, sử dụng `len(self.dataframe)` trả về số lượng dòng hiện tại trong DataFrame, hay cập nhật số lượng dòng trong DataFrame sau khi thêm dòng mới. Cuối cùng, hàm trả về DataFrame đã được cập nhật, cho phép người dùng thấy trạng thái mới của DataFrame sau khi thêm dòng.

Sau khi khởi chạy hàm `create_data()` ta sẽ được kết quả lưu vào file csv như sau:

100	Comedy	New Show	Director N	Cast Name	Country	Date	2021	PG-13	90 min	Comedy	Description of the new show
-----	--------	----------	------------	-----------	---------	------	------	-------	--------	--------	-----------------------------

Hình 19: Kết quả sau khi chạy hàm `create_data()`

2.3.2 Đọc DataFrame

Thao tác đọc DataFrame hay Read trong CRUD là cơ chế cho phép người dùng truy cập và xem dữ liệu hiện có của DataFrame hiện tại.

2.3.3 Cập nhật thông tin của một dòng trong DataFrame

Thao tác cập nhật hay Update trong CRUD cho phép người dùng thay đổi dữ liệu trong một hoặc nhiều dòng dựa trên yêu cầu, điều kiện nhất định.

Khi gọi hàm `update_data(item_id, new_data)`, hàm này sẽ kiểm tra xem `item_id` có tồn tại trong cột `show_id` của DataFrame hay không. Nếu `item_id` tồn tại, hàm sẽ tìm chỉ số bản ghi tương ứng và tiến hành cập nhật các giá trị trong các cột của DataFrame dựa trên dữ liệu mới trong `new_data`. Trong quá trình này, hàm sẽ kiểm tra từng cột trong `new_data` để đảm bảo rằng cột đó cũng tồn tại trong DataFrame hiện tại. Sau đó lưu vào file csv.

Nếu cột nào không tồn tại, hàm sẽ bỏ qua việc cập nhật cho cột đó. Nếu `item_id` không tồn tại trong DataFrame, hàm sẽ in ra thông báo “Không tìm thấy show cần cập nhật.” để thông báo cho người dùng về việc không tìm thấy bản ghi cần cập nhật.

Không tìm thấy show cần cập nhật.

Hình 20: Mô tả xuất ra màn hình khi không tìm được `item_id` cần cập nhật dữ liệu

2.3.4 Xóa một dòng khỏi DataFrame

Thao tác xóa hay Delete trong CRUD cho phép người dùng loại bỏ một hoặc nhiều dòng khỏi DataFrame.

Khi được gọi hàm `delete_data(item_data)` bắt đầu bằng việc Tạo một danh sách rỗng `item_id_exist[]` để lưu trữ các `item_id` mà tồn tại trong DataFrame. Sau đó, duyệt qua từng `item_id` trong danh sách `item_id` được truyền vào. Hàm `self.checkShowID(x)` được gọi để kiểm tra xem `x` có tồn tại trong DataFrame hay không. Nếu có, `x` sẽ được

thêm vào danh sách `item_id_exist`. Sử dụng phương thức `isin()` để kiểm tra xem các giá trị trong cột `show_id` của DataFrame có nằm trong `item_id_exist` hay không. Lấy chỉ số (index) của các dòng mà có `show_id` nằm trong danh sách này và lưu vào `indexes_to_drop`.

s8804	TV Show	Zombie Dumb			1-Jul-19	2018	TV-Y7	2 Seasons	Kids' TV, Ki	While living alone in a spooky t
s8805	Movie	Zombieland	Ruben Flei	Jesse Eiser	United Sta	1-Nov-19	2009	R	88 min	Comedies, Looking to survive in a world ta
s8806	Movie	Zoom	Peter Hew	Tim Allen,	United Sta	11-Jan-20	2006	PG	88 min	Children & Dragged from civilian life, a for
s8807	Movie	Zubaan	Mozez Sing	Vicky Kaus	India	2-Mar-19	2015	TV-14	111 min	Dramas, In A scrappy but poor boy worms
100	Action	Updated S	Updated D	Updated C	USA	Date	2021	PG-13	90 min	Action Updated description

Hình 21: Nội dung file csv trước khi thực hiện hàm xóa

s8804	TV Show	Zombie Dumb			1-Jul-19	2018	TV-Y7	2 Seasons	Kids' TV, Ki	While living alone in a spooky town, a young
s8805	Movie	Zombieland	Ruben Flei	Jesse Eiser	United Sta	1-Nov-19	2009	R	88 min	Comedies, Looking to survive in a world taken over by :
s8806	Movie	Zoom	Peter Hew	Tim Allen,	United Sta	11-Jan-20	2006	PG	88 min	Children & Dragged from civilian life, a former superher
s8807	Movie	Zubaan	Mozez Sing	Vicky Kaus	India	2-Mar-19	2015	TV-14	111 min	Dramas, In A scrappy but poor boy worms his way into

Hình 22: Nội dung file csv sau khi thực hiện hàm xóa

2.4 Phân tích dữ liệu

Sau khi hoàn tất thu thập, làm sạch và chuẩn hóa dữ liệu, bước tiếp theo là phân tích sâu hơn. Nhìn tổng quan, dữ liệu phim và chương trình truyền hình trên Netflix bao gồm nhiều thuộc tính quan trọng như : type, title, director, cast và nhiều yếu tố khác. Mỗi thuộc tính này cung cấp góc nhìn đặc trưng, giúp chúng ta khám phá sâu hơn về xu hướng sản xuất, thị hiếu khán giả và những yếu tố tạo nên sức hút của nội dung. Thông qua việc thống kê và phân tích chi tiết, chúng ta có thể nhận diện xu hướng nội dung theo khu vực, các diễn viên nổi bật, cũng như các thể loại được yêu thích, từ đó tạo cơ sở vững chắc cho các chiến lược nội dung trong tương lai.

Các nội dung cần được thống kê phân tích:

- Thống kê số lượng phim, chương trình truyền hình theo quốc gia
- Thống kê số lượng phim và chương trình truyền hình theo quốc gia.
- Thống kê thời lượng trung bình theo từng năm phát hành.
- Thống kê số lượng phim và chương trình truyền hình sản xuất độc quyền bởi Netflix.
- Thống kê số lượng phim và chương trình truyền hình được chiếu trên Netflix theo từng năm.
- Thống kê top 5 diễn viên có mặt nhiều nhất cho 5 thể loại phổ biến nhất.

- Thống kê top 5 đạo diễn có nhiều phim nhất cho mỗi loại đánh giá.

- Ma trận tương quan giữa các thể loại của TV show, Movie

Class DataAnalyzing

Function __init__():

Hàm khởi tạo nhận df là một DataFrame chứa dữ liệu Netflix và gán nó cho thuộc tính self.df của class. Mục đích của hàm lấy nguồn dữ liệu vào nhằm phục vụ cho các chức năng thông kê và phân tích khác trong class.

Function preprocess_data():

Phương thức này thực hiện một số bước tiền xử lý quan trọng trên DataFrame self.df để chuẩn bị cho các phân tích tiếp theo. Đầu tiên, nó lọc ra các bộ phim và chương trình TV, lưu chúng vào các thuộc tính riêng như self.movies, self.tv_shows, và self.movies_and_shows, giúp việc phân tích theo từng loại nội dung trở nên dễ dàng hơn. Sau đó, nó chuẩn hóa cột date_added thành kiểu dữ liệu datetime để đảm bảo các giá trị ngày tháng là hợp lệ và dễ sử dụng. Tiếp theo, phương thức tách cột genres (nếu chứa nhiều thể loại ngăn cách bởi dấu phẩy) thành các dòng riêng biệt, giúp việc phân tích từng thể loại chi tiết hơn. Cuối cùng, các bước làm sạch dữ liệu và chuyển đổi này giúp chuẩn hóa dữ liệu để chuẩn bị cho các phân tích chuyên sâu hơn.

Function count_movies() và count_tv_shows():

Phương thức count_movies và count_tv_shows đều có chức năng đếm số lượng phim và chương trình TV theo từng quốc gia. Cả hai đều sử dụng cột country, tách các quốc gia thành các dòng riêng biệt, sau đó đếm số lần xuất hiện của từng quốc gia bằng value_counts().sort_index(). Phương thức count_movies chỉ tập trung vào dữ liệu phim, còn count_tv_shows chỉ xem xét chương trình TV. Cả hai phương thức đều giúp hiển thị sự phân bố nội dung Netflix theo quốc gia, cho phép bạn dễ dàng nhận biết các quốc gia nào sản xuất nhiều phim hoặc chương trình TV nhất.

Kết quả trả về :

```

Các hàng có cột 'type' là 'TV show':
country
Argentina      1
Australia      1
Belgium         1
Brazil          4
Canada          8
China           2
Colombia        2
Denmark         2
France          8
Germany         2
Greece          1
India           8
Indonesia       1
Ireland         2
Israel          1
Italy           5
Japan           11
Malaysia        1
Mexico          4
Nigeria        4
Pakistan        1
Philippines     2
Poland          1
Russia          1
Saudi Arabia    1
Singapore       1
South Africa    1
South Korea     12
Spain           9
Taiwan          8
Thailand         5
Turkey          4
United Kingdom  23
United States   41
Name: count, dtype: int64

```

Hình 23: Kết quả xuất ra màn hình khi thực hiện hàm `count_movie()` và `count_tv_shows()`

Function `count_movies_and_shows_by_country()`:

Phương thức `count_movies_and_shows_by_country` kết hợp dữ liệu của cả phim và chương trình TV để đếm tổng số nội dung từ mỗi quốc gia. Nó sử dụng thuộc tính `self.movies_and_shows` để lọc và tách các quốc gia, sau đó đếm số lượng nội dung theo từng quốc gia bằng `value_counts().sort_index()`. Phương pháp này cung cấp cái nhìn tổng thể về nội dung toàn cầu của Netflix, không phân biệt giữa phim và chương trình TV, giúp nhận diện các quốc gia có mức sản xuất nội dung cao nhất.

Kết quả trả về :

```

Số lượng phim và show TV theo quốc gia:
country
Afghanistan    1
Albania        1
Algeria        3
Angola         1
..
Vatican City   1
Venezuela      2
Vietnam        7
West Germany   2
Zimbabwe       1
Name: count, Length: 113, dtype: int64

```

Hình 24: Kết quả xuất ra màn hình khi thực hiện hàm `count_movies_and_shows_by_country()`

Function `average_duration_by_year()`:

Phương thức `average_duration_by_year` tính toán thời lượng trung bình của các bộ phim và chương trình TV theo từng năm phát hành. Bằng cách nhóm dữ liệu theo `release_year` và tính trung bình cột `minutes` (thời lượng), phương thức này giúp nhận biết xu hướng về thời lượng trung bình của nội dung trên Netflix qua từng năm. Điều này có thể cho thấy các thay đổi về thời gian trung bình của phim hoặc chương trình TV theo thời gian.

Kết quả trả về:

```

Thời gian trung bình phim và show TV theo năm phát hành:
release_year
1942    18.000000
1944    76.000000
1945    63.000000
1946    58.000000
1947    42.000000
...
2017    94.553681
2018    96.525661
2019    93.392233
2020    88.906818
2021    92.888199
Name: minutes, Length: 72, dtype: float64

```

Hình 25: Kết quả xuất ra màn hình khi thực hiện hàm `average_duration_by_year()`

Function `exclusive_movies_count()`:

Phương thức `exclusive_movies_count` xác định và đếm số lượng phim độc quyền, tức là những phim có năm phát hành trùng với năm được thêm vào Netflix. Phương thức này lọc các phim có `release_year` trùng với `date_added.dt.year`, sau đó đếm số phim độc quyền theo từng năm. Kết quả từ phương thức này giúp hiển thị mức độ đầu tư của Netflix vào các nội dung độc quyền theo thời gian, và có thể được dùng để đánh giá chiến lược phát triển của nền tảng.

Kết quả trả về:

```

Thống kê số lượng phim độc quyền bởi Netflix:
release_year
2009         1
2012         1
2013         9
2014        15
2015        60
2016       178
2017      406
2018     585
2019     607
2020     678
2021     324
Name: count, dtype: int64
```

Hình 26: Kết quả xuất ra màn hình khi thực hiện hàm `average_duration_by_year()`

Function `count_by_year_added()`:

Phương thức `count_by_year_added` đếm số lượng phim và chương trình TV được thêm vào Netflix trong mỗi năm. Phương thức trích xuất năm từ cột `date_added` và đếm số lượng các hàng tương ứng bằng `value_counts().sort_index()`. Kết quả từ phương thức này giúp phân tích sự tăng trưởng nội dung của Netflix, cho thấy lượng nội dung mới được thêm vào qua từng năm.

Kết quả trả về:

```

Thống kê số lượng phim và show TV theo năm được thêm vào Netflix:
date_added
2008      1
2009      2
2010      1
2011     13
2012      3
2013      7
2014     14
2015     50
2016    202
2017    719
2018   1095
2019   1261
2020   1186
2021    751
Name: count, dtype: int64

```

Hình 27: Kết quả xuất ra màn hình khi thực hiện hàm `count_by_year_added()`

Function `top_5_actors_by_genre()`:

Phương thức `top_5_actors_by_genre` xác định 5 thể loại phim và chương trình phổ biến nhất, và đếm số lần xuất hiện của 5 diễn viên nhiều nhất trong mỗi thể loại. Đầu tiên, phương thức đếm số lượng nội dung theo từng thể loại, sau đó chọn ra 5 thể loại có số lượng phim nhiều nhất. Với mỗi thể loại trong top 5, nó lọc danh sách diễn viên, tách từng diễn viên và đếm số lần xuất hiện của họ để xác định top 5 diễn viên phổ biến. Kết quả từ phương thức này giúp nhận diện những diễn viên nổi bật nhất trong các thể loại chính trên Netflix.

Kết quả trả về:

```

Top 5 diễn viên đóng nhiều phim nhất theo thể loại:
Thể loại International Movies:
cast
Anupam Kher      38
Shah Rukh Khan   31
Om Puri          27
Akshay Kumar     27
Naseeruddin Shah 26
Name: count, dtype: int64

Thể loại Dramas:
cast
Anupam Kher      28
Shah Rukh Khan   28
Naseeruddin Shah 27
Om Puri          20
Amitabh Bachchan 20
Name: count, dtype: int64

Thể loại Comedies:
cast
Anupam Kher      20
Adam Sandler     18
Paresh Rawal     18
Shah Rukh Khan   15
Boman Irani      15
Name: count, dtype: int64

Thể loại Action & Adventure:
cast
Bruce Willis     13
Anupam Kher      12
Amitabh Bachchan 12
Shah Rukh Khan   11
Nicolas Cage      10
Name: count, dtype: int64

Thể loại Independent Movies:
cast
Naseeruddin Shah 10
Rajit Kapoor      8
Adil Hussain       7
Tannishtha Chatterjee 7
Konkona Sen Sharma 7
Name: count, dtype: int64

```

Hình 28: Kết quả xuất ra màn hình khi thực hiện hàm `top_5_actors_by_genre()`

Function `top_5_directors_by_rating()`:

Phương thức `top_5_directors_by_rating` trả về top 5 đạo diễn có nhiều phim nhất cho mỗi loại đánh giá (rating). Phương thức nhóm các bộ phim theo rating, sau đó đếm số lần xuất hiện của từng đạo diễn và chọn ra top 5 đạo diễn cho từng loại rating. Kết quả này cung cấp một cái nhìn rõ ràng về sự phổ biến của các đạo diễn dựa trên loại rating, giúp xác định xem có mối liên hệ nào giữa loại đánh giá và các đạo diễn nổi bật không.

Kết quả trả về:

Top 5 đạo diễn có nhiều phim nhất theo loại đánh giá: Rating G: <pre> director Robert Vince 5 John A. Davis 3 Fred M. Wilcox 3 Ken Hughes 3 Norman Jewison 3 Name: count, dtype: int64 Rating NC-17: director Abdellatif Kechiche 3 Warren P. Sonoda 2 Name: count, dtype: int64 Rating NR: director Victor Zarcoff 3 Dedubrata Pain 3 Adam Nee 3 Adam MacDonald 3 Name: count, dtype: int64 Rating PG: director Robert Rodriguez 13 Steven Spielberg 12 John G. Avildsen 11 Sean McNamee 10 Brian Levant 10 Name: count, dtype: int64 </pre>	Rating TV-PG: <pre> director Heishikesh Mukherjee 12 Toshiya Shinohara 9 Rishi Riza 9 David Dhaan 9 Lekh Tandon 9 Name: count, dtype: int64 Rating TV-Y: director Gwen Rankin 6 TJ Sullivan 6 Iski Radell 6 Gowad Bolton 5 Jayson Thiessen 4 Name: count, dtype: int64 Rating TV-Y7: director William Lau 6 Rajiv Chhikara 4 Kunihiko Yuyama 4 Ryan Gregg 3 Joe Murray 3 Name: count, dtype: int64 Rating TV-Y7-FV: director Chad Van De Kure 2 Mario Gombi 2 Sahas Kaday 2 Name: count, dtype: int64 Rating UR: director Walerian Borowczyk 3 Sylvia Verheyde 3 Dennis Dugan 2 Name: count, dtype: int64 </pre>	Rating PG-13: <pre> director Don Michael Paul 10 Steven Spielberg 9 Barry Sonnenfeld 9 Robert Luketic 8 Andy Tennant 8 Name: count, dtype: int64 Rating R: director Martin Scorsese 16 Noah Baumbach 14 Quentin Tarantino 12 Tillly Hachowski 9 Paul Thomas Anderson 9 Name: count, dtype: int64 Rating TV-14: director Umash Mehra 21 Cathy Garcia-Molina 20 David Dhaan 18 Kunle Afolayan 17 Rajiv Mehra 14 Name: count, dtype: int64 Rating TV-G: director Lucas Margutti 6 Sonnet R. Harjaya 6 Kuno Kameo 5 Cathy Garcia-Molina 5 Justin G. Dyck 5 Name: count, dtype: int64 Rating TV-M: director Jan Suter 20 Youssef Chahine 20 Raúl Campos 18 Anurog Kashyap 15 Haroon Rahoy 13 Name: count, dtype: int64 </pre>
--	--	---

Hình 29: Kết quả xuất ra màn hình khi thực hiện hàm `top_5_directors_by_rating()`

Function `print_summary()`:

Phương thức `print_summary` tổng hợp và hiển thị các kết quả phân tích từ các phương thức khác trong class. Nó gọi lần lượt từng phương thức phân tích và in ra kết quả để người dùng có thể xem toàn bộ dữ liệu phân tích là hình ảnh của kết quả của các function trên. Cụ thể, phương thức in ra số lượng phim và chương trình TV theo quốc gia, thời lượng trung bình, số lượng phim độc quyền, các diễn viên và đạo diễn hàng đầu, cùng với các thống kê thời lượng. Kết quả hiển thị của phương thức này rất hữu ích để nắm bắt tổng quan về dữ liệu mà không cần phải xem từng phương thức một.

Function `calculate_duration_statistics()`:

Phương thức vận dụng thư viện `numpy` để thực hiện một số phép toán - thống kê về thời lượng bộ phim.

```

Thống kê thời gian:
Thời gian trung bình: 99.83195177091183
Tổng thời gian: 529908
Thời gian ngắn nhất: 0
Thời gian dài nhất: 253
Phương sai thời gian: 937.9284289712987
Độ lệch chuẩn thời gian: 30.625617201475283

```

Hình 30: Kết quả xuất ra màn hình khi thực hiện hàm `calculate_duration_statistics()`:

Function genre_correlation():

Phương thức `genre_correlation` trả về hai DataFrame là hai ma trận biểu diễn mối quan hệ và sự tương quan giữa các thể loại phim và các thể loại chương trình truyền hình. Thông qua việc phân tích sự đồng xuất hiện của các thể loại, phương thức giúp xác định những thể loại nào thường kết hợp cùng nhau. Điều này mang lại thông tin giá trị cho các nhà sản xuất, nhà phân phối hoặc các nhà nghiên cứu nội dung, hỗ trợ họ trong việc tối ưu hóa chiến lược sản xuất, phân phối nội dung, hoặc xây dựng các hệ thống gợi ý cá nhân hóa để phục vụ nhu cầu người dùng hiệu quả hơn.

2.5 Trực quan hóa dữ liệu

Lớp **NetflixDataVisualization** cung cấp các công cụ để trực quan hóa và khám phá dữ liệu về nội dung phim và chương trình TV trên **Netflix**. Sử dụng các biểu đồ khác nhau, chúng ta có thể thấy các xu hướng về năm phát hành, quốc gia sản xuất, thể loại, và các yếu tố khác của nội dung. Dưới đây là mô tả chi tiết về cách hoạt động của từng phương thức trong lớp này và ý nghĩa của mỗi biểu đồ.


2.5.1 Phương thức `plot_movies_shows_by_year`

Biểu đồ nhằm thể hiện tỷ lệ giữa hai loại nội dung chính trên Netflix: Phim (Movies) và Chương trình truyền hình (TV Shows). Mục tiêu của biểu đồ là giúp chúng ta hiểu được sự phân bố của hai loại nội dung này, từ đó nhận diện được xu hướng và nội dung được ưu tiên trên nền tảng Netflix.

Như các bạn đã thấy, biểu đồ dạng hình tròn được chia làm hai phần, đại diện cho Movie và TV Show, tỷ lệ phần trăm ở mỗi loại được thể hiện rõ ràng trên biểu đồ, cụ thể Movie chiếm 96.9% và TV Show chiếm 3.1%. Từ số liệu trên cũng phần nào giúp chúng ta phân biệt được sự chênh lệch rõ ràng giữa Movie và TV Show.

Để làm nổi bật nội dung chiếm tỉ lệ thấp hơn nên phần này đã được làm nhô ra một chút so với phần còn lại. Từ biểu đồ cũng cho ta thấy được loại nội dung chiếm tỉ lệ cao hơn là Movie với 96.9% cho thấy được sự ưu tiên rõ ràng trên nền tảng. Ngược lại, loại nội dung TV show chiếm tỉ lệ thấp hơn với 3.1% nhưng vẫn giữ vai trò quan trọng trong việc đa dạng hóa nội dung.

Về tỉ lệ này cũng một phần nào phản ánh lên chiến lược nội dung của Netflix với sự tập trung vào loại Movie nhằm đáp ứng như cầu của đại đa số khán giả.



Hình 31: Biểu đồ tròn (pie chart) để hiển thị tỷ lệ giữa phim (Movie) và chương trình TV (TV Show) trong dữ liệu Netflix.

2.5.2 Phương thức `plot_top_5_actors_by_genre`


Biểu đồ này nhằm thể hiện thời lượng của các phim và chương trình truyền hình trên Netflix. Mục tiêu của biểu đồ này nhằm giúp chúng ta hình dung cách các nội dung được phân bố theo thời lượng từ ngắn tới dài theo phút.

Nhìn vào biểu đồ, trục X được gán nhãn là chỉ số thời lượng, tức là đại diện cho vị trí của từng nội dung trong tập dữ liệu. Mỗi điểm tương ứng với một phim hoặc một chương trình truyền hình. Trục Y biểu thị thời lượng của nội dung, tính bằng phút.

Nhìn vào biểu đồ thông qua màu sắc từ lạnh tới nóng ta có thể hiện đó là mức độ tăng dần của thời lượng của phim hoặc chương trình truyền hình. Và đặc biệt nhằm giúp trực quan hơn trong việc xác định các nội dung có thời lượng nổi bật thì các điểm đại diện được tăng dần kích thước khi có thời lượng lớn hơn.

Dựa vào biểu đồ, chúng ta cũng có thể nhận ra một số đặc điểm chính: Phần lớn các nội dung có thời lượng ở mức trung bình, tập trung quanh một khoảng nhất định trên trục Y, cụ thể là từ khoảng 75 đến 125. Có một vài điểm lớn hơn và màu đỏ đậm

cho thấy đây là nội dung có thời lượng dài hơn mức trung bình. Ngược lại các điểm nhỏ hơn, màu nhạt hơn, đại diện cho các nội dung có thời lượng ngắn hơn.




Hình 32: Biểu đồ phân tán (scatter plot) để biểu diễn sự phân bố của thời lượng (minutes) các phim và chương trình TV trên Netflix.

Tóm lại, biểu đồ này cung cấp cái nhìn trực quan về sự phân bố thời lượng của phim và chương trình truyền hình trên Netflix. Nó không chỉ giúp chúng ta nhận biết xu hướng thời lượng trung bình mà còn làm nổi bật các nội dung đặc biệt với thời lượng vượt trội.

2.5.3 Phương thức `plot_movie_tv_show_distribution_by_country`

Biểu đồ cột thể hiện số lượng phim và chương trình truyền hình được phát hành trên Netflix qua các năm, giúp chúng ta hiểu rõ xu hướng phát hành nội dung qua thời gian và khám phá các giai đoạn tăng trưởng hoặc suy giảm.

Nhìn vào biểu đồ, trục X biểu diễn các năm phát hành, mỗi cột tương ứng với một năm cụ thể, trục Y biểu thị số lượng phim và chương trình truyền hình phát hành trong từng năm. Chiều cao của cột cho biết mức độ sản xuất nội dung trong năm đó.




Hình 33: Biểu đồ cột (bar chart) để biểu diễn số lượng phim và chương trình TV được phát hành theo từng năm.

Từ biểu đồ, chúng ta có thể thấy, Có một số năm nổi bật với số lượng phát hành cao nhất. Điều này có thể liên quan đến sự mở rộng của Netflix hoặc xu hướng tăng cường sản xuất nội dung độc quyền. Ngược lại, có những giai đoạn số lượng phát hành thấp, có thể do hạn chế về công nghệ hoặc chiến lược kinh doanh của công ty. Một điểm thú vị khác là trong những năm gần đây, số lượng phát hành tăng rõ rệt, cho thấy sự bùng nổ của ngành công nghiệp giải trí và dịch vụ streaming.

2.5.4 Phương thức plot_top_genres

Biểu đồ này thể hiện số lượng phim và chương trình truyền hình được thêm vào nền tảng Netflix qua từng năm, giúp chúng ta hiểu rõ hơn về sự mở rộng nội dung của Netflix và sự phát triển của nền tảng trong những năm qua.

Nhìn vào biểu đồ ta thấy rõ được, giai đoạn ban đầu, số lượng nội dung được thêm vào còn ít, phản ánh thời kỳ đầu của Netflix khi mới chuyển đổi sang nền tảng streaming. Trong một vài năm gần đây, số lượng nội dung tăng vọt. Điều này có thể liên quan đến việc mở rộng thị trường toàn cầu và đầu tư mạnh mẽ vào sản xuất nội dung độc quyền. Một số năm có sự giảm nhẹ, có thể liên quan đến các yếu tố như thay đổi chiến lược hoặc tác động của các yếu tố kinh tế xã hội.




Hình 34: Biểu đồ đường kết hợp vùng tô (line plot with filled area) để biểu diễn xu hướng số lượng phim và chương trình TV được thêm vào Netflix theo từng năm.

Tóm lại, biểu đồ này cung cấp một cái nhìn trực quan về sự phát triển của Netflix qua các năm thông qua việc thêm mới nội dung. Rõ ràng là có một sự tăng trưởng đáng kể trong những năm gần đây, chứng tỏ Netflix đã trở thành một phần quan trọng của ngành công nghiệp giải trí số.

2.5.5 Phương thức `plot_movie_vs_tv_show_distribution`

Biểu đồ này thể hiện số lượng phim độc quyền được Netflix phát hành qua các năm, giúp chúng ta hiểu rõ hơn về xu hướng và chiến lược phát triển nội dung độc quyền của Netflix theo thời gian

Nhìn vào biểu đồ ta có thể thấy, Trục X biểu diễn các năm phát hành phim độc quyền. Các điểm đánh dấu (marker) trên đường giúp xác định rõ số lượng phim cho từng năm, Trục Y biểu thị số lượng phim độc quyền phát hành trong mỗi năm. Đường màu xanh lá nối các điểm dữ liệu giúp thể hiện xu hướng tăng giảm số lượng phim độc quyền theo thời gian.



Hình 35: Biểu đồ đường (line plot) để hiển thị số lượng phim độc quyền do Netflix phát hành qua các năm.

Trong giai đoạn đầu, số lượng phim độc quyền còn khá ít, cho thấy Netflix mới bắt đầu thử nghiệm mô hình nội dung này,

Có một sự gia tăng đáng kể trong các năm tiếp theo, thể hiện rõ chiến lược tập trung vào sản xuất và phát hành nội dung độc quyền,

Một số năm có thể xuất hiện mức độ tăng chậm lại hoặc giảm nhẹ, điều này có thể phản ánh sự thay đổi chiến lược hoặc sự bão hòa của thị trường nội dung độc quyền.


Tóm lại, biểu đồ này cho thấy một xu hướng quan trọng trong chiến lược phát triển của Netflix, đó là đầu tư mạnh mẽ vào nội dung độc quyền. Đây là một trong những yếu tố giúp Netflix nổi bật trong ngành công nghiệp giải trí số.

2.5.6 Phương thức `plot_exclusive_movies_by_year`

Biểu đồ thanh ngang thể hiện Top 5 thể loại phổ biến nhất trên Netflix, giúp chúng ta hiểu được xu hướng và thị hiếu người dùng đối với các thể loại nội dung trên nền tảng Netflix.

Trục X biểu diễn số lượng phim hoặc chương trình thuộc từng thể loại.

Trục Y liệt kê các thể loại phổ biến, được xếp từ trên xuống theo thứ tự giảm dần của số lượng.



Hình 36: Biểu đồ cột ngang (horizontal bar chart) để hiển thị các thể loại phổ biến nhất trên Netflix, dựa trên số lượng xuất hiện.

Quan sát biểu đồ, chúng ta có thể nhận ra:

- Thể loại đứng đầu có số lượng lớn nhất, điều này phản ánh thị hiếu phổ biến của người xem Netflix.
- Các thể loại tiếp theo giảm dần về số lượng, nhưng vẫn chiếm một phần đáng kể trong tổng nội dung.
- Khoảng cách giữa các thể loại, điều này có thể chỉ ra sự khác biệt rõ ràng trong thị hiếu người dùng.


Tóm lại, biểu đồ này cung cấp một cái nhìn tổng quan về những thể loại được ưa chuộng nhất trên Netflix. Kết quả này có thể giúp Netflix đưa ra các chiến lược phù hợp để mở rộng và phát triển nội dung.

2.5.7 Phương thức plot_added_year_trend

Biểu đồ này thể hiện danh sách Top 5 diễn viên phổ biến nhất trong từng thể loại phim trên Netflix, giúp chúng ta hiểu rõ hơn về mức độ đóng góp của các diễn viên trong việc tạo nên sức hút cho từng thể loại.

Biểu đồ này bao gồm nhiều đồ thị con, mỗi đồ thị đại diện cho một thể loại phim phổ biến.

Trục X biểu diễn tên các diễn viên. Trục Y biểu thị số lượng phim mà diễn viên đó tham gia trong thể loại.



Hình 37: Biểu đồ cột (bar chart) để hiển thị Top 5 diễn viên phổ biến nhất trong từng thể loại phim, được trình bày dưới dạng nhiều biểu đồ nhỏ (subplots), mỗi biểu đồ đại diện cho một thể loại.

Quan sát biểu đồ, chúng ta có thể thấy các điểm đáng chú ý như:

Sự khác biệt giữa Top 1 và các vị trí tiếp theo có thể chỉ ra mức độ ảnh hưởng hoặc sự quen thuộc của diễn viên đó trong thể loại này.

Sự hiện diện của một số diễn viên trong nhiều thể loại có thể cho thấy sự đa dạng hoặc phổ biến của họ trên Netflix.

Mỗi thể loại đều có một số diễn viên nổi bật với số lượng phim tham gia vượt trội so với các diễn viên khác.


Biểu đồ này cung cấp một cái nhìn sâu sắc về vai trò của các diễn viên trong việc xây dựng sức hấp dẫn của các thể loại phim trên Netflix. Đây là một chỉ báo quan trọng cho các nhà sản xuất nội dung và chiến lược phát triển nền tảng.

2.5.8 Phương thức plot_duration_distribution

Biểu đồ này thể hiện Top 1 đạo diễn có số lượng phim cao nhất theo từng loại đánh giá, giúp chúng ta nhận ra sự đóng góp nổi bật của các đạo diễn trong từng phân khúc đánh giá, đồng thời cho thấy mức độ phổ biến của họ đối với các loại nội dung.

Trục X biểu thị số lượng phim mà các đạo diễn đã thực hiện trong một loại đánh giá cụ thể.

Trục Y liệt kê các loại đánh giá, chẳng hạn như G (General), PG (Parental Guidance), R (Restricted)...



Hình 38: Biểu đồ cột ngang (horizontal bar chart) để hiển thị Top 1 đạo diễn có số lượng phim nhiều nhất trong mỗi loại đánh giá (rating).

Quan sát biểu đồ, ta có thể thấy:

Mỗi loại đánh giá đều có một đạo diễn nổi bật với số lượng phim lớn nhất.

Sự khác biệt trong số lượng phim giữa các loại đánh giá có thể cho thấy sự chuyên môn hóa của các đạo diễn hoặc sự phù hợp của họ với đối tượng khán giả cụ thể.

Các loại đánh giá có ít số lượng phim có thể phản ánh những phân khúc khán giả hẹp hơn hoặc ít được đầu tư hơn.


Tóm lại, biểu đồ này cung cấp một cái nhìn toàn cảnh về sự đóng góp của các đạo diễn trong từng phân khúc đánh giá. Đây là thông tin hữu ích để xác định những người dẫn đầu và tìm kiếm cơ hội mở rộng trong lĩnh vực làm phim.

2.5.9 Phương thức `plot_top_directors_by_rating`

Mục đích hiển thị top 10 quốc gia có số lượng phim và chương trình TV nhiều nhất trên nền tảng Netflix. Việc phân tích này giúp chúng ta hiểu được sự phân bố nội dung của Netflix trên toàn cầu và xác định các quốc gia có ảnh hưởng lớn đến thư viện nội dung của nền tảng.

Trục x: Hiển thị các quốc gia với số lượng phim và chương trình TV được thêm vào nền tảng.

Trục y: Số lượng phim và chương trình TV



Hình 39: Biểu đồ cột (bar chart) để hiển thị Top 10 quốc gia sản xuất nhiều phim và chương trình TV nhất trên Netflix.

Từ biểu đồ này, chúng ta có thể rút ra các điểm quan trọng sau:

- Các quốc gia chiếm ưu thế: Biểu đồ giúp xác định quốc gia nào đóng góp nhiều nhất vào thư viện nội dung của Netflix.
- Xu hướng phân bố nội dung: Việc biết được sự phân bố của nội dung theo quốc gia giúp Netflix điều chỉnh chiến lược hợp tác và phát triển nội dung sao cho phù hợp với nhu cầu của các khu vực khác nhau.
- Định hình chiến lược phát triển: Dữ liệu này có thể giúp Netflix xác định những quốc gia mà họ cần tập trung vào để tăng cường sản xuất hoặc hợp tác với các nhà sản xuất nội dung địa phương.

Biểu đồ này không chỉ giúp chúng ta nhận diện các quốc gia chủ chốt trong việc cung cấp nội dung cho Netflix mà còn phản ánh chiến lược của nền tảng trong việc phát triển thư viện nội dung toàn cầu. Phân tích này có thể cung cấp thông tin quan trọng cho các nhà quản lý nội dung và chiến lược phát triển sản phẩm của Netflix.


2.5.10 Phương thức `plot_correlation_matrix`

Biểu đồ ma trận tương quan thể loại cho chương trình truyền hình (TV Shows Genre Correlation), giúp chúng ta hiểu rõ hơn về mối quan hệ giữa các thể loại chương trình truyền hình trên Netflix.

Như các bạn có thể thấy:

- Trục X và trục Y thể hiện các thể loại chương trình truyền hình.
- Mỗi ô trong biểu đồ là một giá trị tương quan giữa hai thể loại.
- Màu sắc biểu thị độ mạnh của mối quan hệ:
 - Màu đỏ đậm cho thấy mối tương quan dương mạnh (tức là hai thể loại thường xuất hiện cùng nhau).
 - Màu xanh đậm đại diện cho tương quan âm mạnh (hai thể loại ít xuất hiện cùng nhau).

- Màu trung tính (gần trắng) cho thấy mỗi tương quan yếu hoặc không có mối quan hệ đáng kể.



Hình 40: Ma trận tương quan (correlation matrix) để trực quan hóa mức độ tương quan giữa các thể loại phim truyền hình.

Tóm lại, biểu đồ tương quan này cho thấy bức tranh toàn diện về mối quan hệ giữa các thể loại chương trình truyền hình. Điều này không chỉ giúp chúng ta hiểu hơn về xu hướng nội dung trên Netflix mà còn mở ra những cơ hội sáng tạo mới.


2.5.11 Phương thức `plot_correlation_matrix()`

Biểu đồ ma trận tương quan thể loại phim (Movies Genre Correlation), giúp chúng ta phân tích mức độ liên kết giữa các thể loại phim và cách chúng xuất hiện cùng nhau trên Netflix.

Như các bạn có thể thấy:

- Trục X và trục Y thể hiện các thể loại phim khác nhau.
- Mỗi ô trong ma trận biểu diễn giá trị tương quan giữa hai thể loại.
- Màu sắc được sử dụng để biểu thị độ mạnh và tính chất của mỗi tương quan:

- Màu đỏ đậm cho thấy mối tương quan dương mạnh (các thể loại này thường xuất hiện cùng nhau).
- Màu xanh đậm biểu thị tương quan âm mạnh (các thể loại này hiếm khi xuất hiện cùng nhau).
- Màu gần như trắng cho thấy mối tương quan yếu hoặc không có sự liên kết rõ ràng



Hình 41 : Ma trận tương quan (correlation matrix) để trực quan hóa mức độ tương quan giữa các thể loại phim.

Tóm lại, biểu đồ ma trận tương quan này mang đến cái nhìn tổng thể về sự liên kết giữa các thể loại phim trên Netflix. Việc phân tích này có thể hỗ trợ việc phát triển nội dung phù hợp với thị hiếu của khán giả.

CHƯƠNG 3: GIAI ĐOẠN THIẾT KẾ GIAO DIỆN

3.1 Menu chức năng

3.1.1 Tổng quan về menu chức năng

Chương trình cung cấp một menu điều khiển chính cho người dùng tương tác với dữ liệu phim trên nền tảng Netflix bằng màn hình Console. Các chức năng chính trong chương trình bao gồm:

Overview: Xem thông tin tổng quan về tập dữ liệu đầu vào Dataset.

```
--- Overview về dataset ---  
1. Dataset Overview  
2. Về menu chính  
Nhập vào lựa chọn của bạn: █
```

Hình 42: Giao diện chức năng Overview

Data Cleaning: Làm sạch và chuẩn hóa dữ liệu.

```
----- Data Cleaning -----  
1. Xử lý giá trị null  
2. Xử lý giá trị Duplicate  
3. Chuẩn hóa kiểu dữ liệu  
4. Chuẩn hóa Dataframe  
5. DataType của dataframe  
6. Về menu chính  
Nhập vào lựa chọn của bạn: █
```

Hình 43: Giao diện chức năng Data Cleaning

CRUD: Thêm, xóa, và cập nhật dòng Record cho Data Frame (Bảng sao của Dataset đầu vào)

```
----- CRUD -----
1. Thêm dòng record
2. Xóa dòng record
3. Cập nhật dòng record
4. Về menu chính
Nhập vào lựa chọn của bạn: █
```

Hình 44: Giao diện chức năng CRUD

Ngoài ra còn một số tính năng khác:

```
--- Đồ Án Phân Tích Dữ Liệu Phim Trên Netflix ---
1. Overview
2. Data Cleaning
3. CRUD
4. Data Analyzing
5. Data Visualization
6. Xuất ra Datasets hiện tại
7. Xem DataFrame hiện tại
8. Thoát
Chọn một chức năng: █
```

Hình 45: Giao diện tổng quan của ứng dụng

Data Analyzing: Phân tích dữ liệu và tóm tắt các thống kê

Data Visualization: Trực quan hóa dữ liệu dưới dạng các biểu đồ thống kê

Xuất Datasets: Lưu lại tập dữ liệu DataFrame đã được làm sạch dưới dạng file CSV.

Xem DataFrame hiện tại: Xem dữ liệu hiện tại trong DataFrame.

Thoát: Thoát khỏi chương trình.

3.1.2 Chức năng của các menu con

- **Menu Overview:** Menu này cho phép người dùng xem thông tin tổng quan về dataset bao gồm:

- + Kiểu dữ liệu của các cột.
- + Kích thước và cấu trúc của DataFrame.
- + Các giá trị xuất hiện nhiều nhất trong mỗi cột.
- + Các thông tin mô tả chung về dữ liệu.

- **Menu Data Cleaning:** Chức năng làm sạch dữ liệu bao gồm các tùy chọn:

+ Xử lý các giá trị null: Người dùng có thể chọn xóa hoặc giữ các giá trị null có trong dataset

+ Xử lý giá trị duplicate: Cho phép loại bỏ các bản sao trùng lặp.

+ Chuẩn hóa kiểu dữ liệu: Chuyển đổi kiểu dữ liệu cho các cột như date_added và phân chia cột duration thành minutes và season.

+ Chuẩn hóa DataFrame: Loại bỏ các ký tự lạ, đổi tên cột, và chuẩn hóa dữ liệu cho các cột.

+ Hiển thị kiểu dữ liệu của DataFrame: Cung cấp thông tin về kiểu dữ liệu của các cột trong dataset.

- **Menu CRUD (Create, Read, Update, Delete):** Menu này cho phép người dùng thao tác với dữ liệu:

+ Thêm dòng record: Nhập các thông tin để tạo một dòng mới trong dataset (bao gồm ID, loại sản phẩm, tựa phim, đạo diễn, diễn viên, quốc gia, năm phát hành, v.v...).

+ Xóa dòng record: Xóa các bản ghi dựa trên ID.

+ Cập nhật dòng record: Cập nhật thông tin của một bản ghi cụ thể.

+ **Menu Data Analyzing:** Dành cho người dùng muốn phân tích dữ liệu. Chức năng này yêu cầu dữ liệu đã được làm sạch (checkClean và checkClean2 phải là True). Nó sẽ thực hiện các bước phân tích tổng quan về dataset.

- **Menu Data Visualization:** Menu này cung cấp các biểu đồ trực quan để người dùng hiểu sâu hơn về dữ liệu, bao gồm các biểu đồ:

- + Tỷ lệ Phim và Chương trình TV trên Netflix
- + Phân phối Thời lượng Phim trên Netflix
- + Số lượng phim và chương trình theo năm phát hành
- + Số lượng Phim và Chương trình TV được đưa vào nền tảng Netflix theo năm
- + Số lượng Phim Độc Quyền phát hành bởi Netflix theo Năm
- + Top 10 Quốc Gia có nhiều Phim và Chương Trình TV trên Netflix
- + Top 5 Thể loại Phổ biến trên Netflix
- + Top 5 Diễn viên trong các Thể loại Phim phổ biến
- + Top Đạo diễn có nhiều phim nhất theo loại đánh giá
- + Biểu đồ tương quan của Movie và TV Show về Genres

3.1.3 Chức năng xuất dữ liệu và xem DataFrame hiện tại

- **Xuất Datasets hiện tại:** Xuất DataFrame hiện tại ra file CSV (clean_data1.csv).

- **Xem DataFrame hiện tại:** Hiển thị nội dung của DataFrame hiện tại trong console cho người dùng.

3.1.4. Chức năng thoát chương trình

Khi người dùng chọn “Thoát”, chương trình sẽ dừng và hiển thị thông báo tạm biệt.

3.2 Xây dựng giao diện UI với thư viện Tkinter

3.2.1 Tổng quan về giao diện UI

Chương trình này sử dụng thư viện Tkinter để xây dựng một giao diện người dùng đồ họa (GUI), cho phép người dùng tương tác dễ dàng với dữ liệu phim trên nền tảng Netflix. Giao diện chính cung cấp đầy đủ các chức năng của dự án thông qua các nút bấm Button trực quan. Các nút bấm được phân bố hợp lý, tạo cảm giác thân thiện

và dễ sử dụng cho người dùng. Các nhóm chức năng liên quan được sắp xếp một cách hợp lý, giúp người dùng dễ dàng tìm kiếm và thực hiện các thao tác.



Hình 46: Giao diện phần mềm với thư viện Tkinter


3.2.2 Các nhóm chức năng trong giao diện

Nhóm chức năng CLEANING: Bao gồm các Button:




Hình 47: Giao diện nhóm chức năng CLEANING

+ **Xử lý giá trị Null:** Người dùng có thể chọn xóa hoặc giữ các giá trị null có trong dataset



Hình 48: Thông báo từ messagebox khi tiến hành xử lý các giá trị Null


Nếu người dùng đã xử lý giá trị NULL, hệ thống sẽ hiển thị dòng messagebox



Hình 49: Thông báo từ messagebox khi đã xử lý các giá trị Null trước đó


+ **Xử lý giá trị Duplicate:** Người dùng có thể chọn xóa hoặc giữ các bản sao trùng lặp có trong dataset

Thông báo từ messagebox:



Hình 50: Thông báo từ messagebox khi tiến hành xử lý các giá trị Duplicate


Nếu người dùng đã xử lý giá trị NULL, hệ thống sẽ hiển thị dòng messagebox



Hình 51: Thông báo từ messagebox khi đã xử lý các giá trị Duplicate trước đó


+ **Chuẩn hóa kiểu dữ liệu:** Chuyển đổi kiểu dữ liệu cho các cột như date_added và phân chia cột duration thành minutes và season.

Thông báo từ messagebox:



Hình 52: Thông báo từ messagebox khi lựa chọn chuẩn hóa kiểu dữ liệu


Sau khi chuẩn hóa thành công:



Hình 53: Thông báo từ messagebox khi chuẩn hóa kiểu dữ liệu hoàn tất


Chuẩn hóa DataFrame: Loại bỏ các ký tự lạ, đổi tên cột, và chuẩn hóa dữ liệu cho các cột.

Thông báo từ messagebox:




Hình 54: Thông báo từ messagebox khi lựa chọn chuẩn hóa DataFrame

Sau khi chuẩn hóa:



Hình 55: Thông báo từ messagebox khi chuẩn hóa DataFrame hoàn tất

+ **DataType của DataFrame:** Cung cấp thông tin về kiểu dữ liệu của các cột trong dataset.



Hình 56: Mô tả minh họa thông báo hiển thị các kiểu dữ liệu của Dataframe


- **Nhóm chức năng CRUD, sắp xếp và tìm kiếm trên Dataframe:** Bao gồm các Button:



Hình 57: Giao diện nhóm chức năng CRUD

- + **Cập nhật dữ liệu:** Cập nhật thông tin của một bản ghi cụ thể.

Khi thao tác trên nút chức năng này, người dùng sẽ có một ô nhập thông tin, bao gồm giá trị show_id cần cập nhật thông tin và các trường dữ liệu bắt buộc của một bản ghi. Người dùng có thể tìm kiếm show_id trước khi tiến hành cập nhật bằng cách nhấn vào button **Tìm kiếm**.




Hình 58: MessageBox thông báo khi thao tác tìm kiếm không tìm thấy giá trị `show_id` cần cập nhật dữ liệu

Nếu người dùng tìm thấy `show_id`, thì tự động các trường dữ liệu sẽ được thêm vào giúp cho việc thao tác và thay đổi nhanh chóng, tiện lợi

A screenshot of a web application window titled 'Cập Nhật Dữ Liệu'. The window has a light gray background and standard window controls (minimize, maximize, close). It contains a form with the following fields: 'show_id' (text), 'type' (text), 'title' (text), 'director' (text), 'cast' (text), 'country' (text), 'date_added' (text), 'release_year' (text), 'rating' (text), 'duration' (text), 'genres' (text), 'description' (text), 'minutes' (text), and 'season' (text). At the bottom of the form are two blue buttons with white text: 'Tìm kiếm' and 'Cập nhật'.

Hình 59: Hình ảnh ô nhập tự động điền giá trị hiện tại khi tìm thấy giá trị `show_id`



Hình 60: Hình ảnh thông báo cập nhật dữ liệu thành công

+ **Xóa bản ghi:** Xóa các bản ghi dựa trên ID.

Người dùng có thể chọn một hoặc nhiều dòng (nhấn giữ phím CTRL và chọn dòng cần xóa) để thao tác xóa bản ghi khỏi dataframe hiện tại.

ỨNG DỤNG PHÂN TÍCH DỮ LIỆU HỆ THỐNG PHIM CỦA NETFLIX


PHÂN TÍCH DỮ LIỆU HỆ THỐNG PHIM CỦA NETFLIX

===== BẢNG DỮ LIỆU =====

show_id	type	title	director	cast	country	date_added	release_year	rating	duration	genres	description	minutes	season
s6706	Movie	Españoles La Carr	Aljendo Doris	Luis Brandoni, Chi	Argentina	2018-07-15 00:00:00	1985.0	NR	95 min	Comedies, Cult M	Cine has three sex	95	0
s4850	Movie	Fernando Sanja	Rafael Campos, Jar	Fernando Sanja	Argentina	2018-05-25 00:00:00	2018.0	TV-MAA	63 min	Stand-Up Comedy	Argentine actor as	63	0
s1527	Movie	Gal Tha Unforgett	Maura Scandolaci	Filar Pascual, Juliá	Argentina	2019-11-15 00:00:00	2019.0	TV-PG	60 min	Children & Family	MM, a's vacation s	60	0
s1315	Movie	Grego Rossetti: Di	Juan L. Chonetti	Grego Rossetti	Argentina	2019-10-31 00:00:00	2019.0	TV-MAA	65 min	Stand-Up Comedy	Argentine's comed	65	0
s7025	Movie	Hypocritas	Gabriel Göttsche	Namika Saut, Sara	Argentina	2017-06-28 00:00:00	2016.0	TV-MAA	84 min	Horror Movies, Int	As young actors as	84	0
s2466	Movie	Insultum	Aljendo Montiel	Luisana Lopate, J	Argentina	2020-05-20 00:00:00	2020.0	TV-MAA	116 min	Dramas, Internatic	Police officer Pipe	116	0
s4174	Movie	Just Love	Andy Caballero, D	Franco Masini, Ya	Argentina	2019-01-24 00:00:00	2018.0	TV-MAA	96 min	Dramas, Internatic	Inspired by his lov	96	0
s7251	Movie	La Última Fiesta	Leandro Mark, Nic	Nicolas Vázquez	Argentina	2017-02-01 00:00:00	2016.0	TV-MAA	104 min	Comedies, Internat	Three best buddies	104	0
s7559	Movie	Lucha Playing The	Ana Quiroga	Luciana Aymar	Argentina	2018-07-15 00:00:00	2018.0	TV-PG	98 min	Documentaries, Ir	Known simply as	98	0
s4732	Movie	Luciano Melina: A	Rafael Campos, Jar	Luciano Melina	Argentina	2018-07-26 00:00:00	2018.0	TV-14	66 min	Stand-Up Comedy	Argentina's Lucian	66	0


Cập nhật dữ liệu Xóa bản ghi Thêm bản ghi Sắp xếp theo show_id Tựa đề Giản đồ Tìm kiếm Thoát

Hình 61: Tiến hành chọn các dòng cần xóa dữ liệu




Hình 62: Hình ảnh thông báo cập xóa dữ liệu thành công


+ **Thêm bản ghi:** Nhập các thông tin để tạo một dòng mới trong dataset (bao gồm ID, loại sản phẩm, tựa phim, đạo diễn, diễn viên, quốc gia, năm phát hành, v.v...)



Hình 63: Hình ảnh giao diện nhập thông tin cho dòng Record mới



Hình 64: Hình ảnh thông báo lỗi khi người dùng nhập sai định dạng cho Record mới



Hình 65: Hình ảnh thông báo sau khi thêm dữ liệu thành công

+ **Sắp xếp theo cột:** Bao gồm các lựa chọn cột: show_id, title, minutes, season, release_year, giúp sắp xếp bảng dữ liệu Dataframe hiện tại theo thứ tự bảng chữ cái tăng / giảm dần, giúp người dùng dễ dàng xem bảng dữ liệu.

Ví dụ: Sắp xếp tăng dần theo cột show_id

PHÂN TÍCH DỮ LIỆU HỆ THỐNG PHIM CỦA NETFLIX													
===== BẢNG DỮ LIỆU =====													
show_id	type	title	director	cast	country	date_added	release_year	rating	duration	genres	description	minutes	season
s8	Movie	Sankofa	Halle Gerima	Kofi Olanibisi, Oyi	United States, Gha	2021-09-24 00:00:00	1990.0	TV-MA	125 min	Dramas, Independent	On a photo shoot	125	0
s9	TV Show	The Great British B	Andy Devenish	Mai Gidycz, Sue	United Kingdom	2021-09-24 00:00:00	2021.0	TV-14	9 seasons	British TV Shows, I	A talented batch o	0	9
s10	Movie	The Starling	Theodore Melfi	Melissa McCarthy	United States	2021-09-24 00:00:00	2021.0	PG-13	104 min	Comedies, Drama	A woman adjuster	104	0
s13	Movie	Je Suis Karl	Christian Schoed	Luna Wedler, Jan	Germany, Czech R	2021-09-21 00:00:00	2021.0	TV-MA	127 min	Dramas, Internatio	After most of her	127	0
s25	Movie	Jeans	S. Shankar	Prashanth, Aishw	India	2021-09-21 00:00:00	1998.0	TV-14	166 min	Comedies, Internat	When the father o	166	0
s28	Movie	Grown Ups	Dennis Dugan	Adam Sandler, Ke	United States	2021-09-20 00:00:00	2010.0	PG-13	103 min	Comedies	Mourning the loss	103	0
s29	Movie	Dark Sites	Scott Stewart	Keri Russell, Josh	United States	2021-09-19 00:00:00	2013.0	PG-13	97 min	Horror Movies, Sc	A family's cryptic c	97	0
s30	Movie	Paranoia	Robert Luketic	Liam Hemsworth	United States, Indi	2021-09-19 00:00:00	2013.0	PG-13	106 min	Thrillers	Blackmailed by hi	106	0
s39	Movie	Birth Of The Drago	George Nolfi	Billy Magnussen, I	China, Canada, Ur	2021-09-16 00:00:00	2017.0	PG-13	96 min	Action & Adventu	A young Bruce Le	96	0
s42	Movie	Jaws	Steven Spielberg	Roy Scheider, Rob	United States	2021-09-16 00:00:00	1975.0	PG	124 min	Action & Adventu	When an insatiable	124	0

Hình 66: Hình ảnh chức năng sắp xếp trên giao diện UI

+ **Ô tìm kiếm:** Nhập từ khóa tìm kiếm, sau đó nhấn button Tìm kiếm, ứng dụng sẽ liệt kê tất cả các Record chứa từ khóa cần tìm có trong các cột.

Ví dụ: Tìm kiếm từ khóa “Viet Nam”

PHÂN TÍCH DỮ LIỆU HỆ THỐNG PHIM CỦA NETFLIX													
===== BẢNG DỮ LIỆU =====													
show_id	type	title	director	cast	country	date_added	release_year	rating	duration	genres	description	minutes	season
s808	TV Show	test	giang	giang	viet nam	11/6/2015	2015	R	10 Season	drama	hay	0	10


Hình 67: Hình ảnh chức năng tìm kiếm trên giao diện UI

- + **Thoát:** Thoát kết quả tìm kiếm, hiển thị lại bảng dataframe đầy đủ.
- + **Back:** Lùi về trang dữ liệu liền sau so với trang hiện tại.
- + **Next:** Tiến tới trang dữ liệu kế tiếp so với trang hiện tại.
- **Nhóm chức năng ACTIVITY:** Bao gồm các Button:




Hình 68: Giao diện nhóm chức năng ACTIVITY

- + **Dataset Analyzing:** In ra messagebox thông tin phân tích từ dữ liệu DataFrame



Hình 69: Thông báo messagebox từ nút lệnh Data Analyzing

- + **Xuất Datasets hiện tại:** Xuất DataFrame hiện tại ra file CSV (clean_data1.csv).



Hình 70: Thông báo messagebox từ nút lệnh Data Overview

+ **Xem DataFrame hiện tại:** Hiển thị nội dung của DataFrame hiện tại trong giao diện Tkinter cho người dùng dưới dạng bảng Treeview.

- **Nhóm chức năng VISUALIZATION DATA:** Bao gồm các Button:

+ **Tỷ lệ Phim và Chương trình TV trên Netflix:** Hiển thị biểu đồ tỷ lệ giữa Phim và Chương trình TV trên Netflix.

+ **Phân phối Thời lượng Phim trên Netflix:** Hiển thị biểu đồ phân phối thời gian dài của các phim trên Netflix.

+ **Số lượng phim và chương trình theo năm phát hành:** Hiển thị biểu đồ đếm số lượng phim và chương trình theo năm phát hành.

+ **Số lượng Phim và Chương trình TV được đưa vào nền tảng Netflix theo năm:** Hiển thị biểu đồ đếm số lượng phim và chương trình được thêm vào nền tảng Netflix theo từng năm.

+ **Số lượng Phim Độc Quyền phát hành bởi Netflix theo Năm:** Hiển thị biểu đồ đếm số lượng phim độc quyền phát hành bởi Netflix theo năm.

+ **Top 10 Quốc Gia có nhiều Phim và Chương Trình TV trên Netflix:** Hiển thị biểu đồ top 10 quốc gia có nhiều phim và chương trình TV nhất trên Netflix.

+ **Top 5 Thể loại Phổ biến trên Netflix:** Hiện thị biểu đồ liệt kê 5 thể loại phổ biến nhất trên Netflix.

+ **Top 5 Diễn viên trong các Thể loại Phim phổ biến:** Hiện thị biểu đồ liệt kê top 5 diễn viên trong các thể loại phim phổ biến trên Netflix.

+ **Top Đạo diễn có nhiều phim nhất theo loại đánh giá:** Hiện thị biểu đồ liệt kê top đạo diễn có nhiều phim nhất theo loại đánh giá trên Netflix.

+ **Biểu đồ tương quan của Movie và TV Show về Genres:** Hiện thị hai biểu đồ tương quan của Movie và TV Show về Genres.



Hình 71: Minh họa giao diện một vài biểu đồ mẫu

VISUALIZATION DATA			
Tỷ lệ Phim và Chương trình TV trên Netflix	Phân phối Thời lượng Phim trên Netflix	Số lượng phim và chương trình TV được đưa vào nền tảng Netflix theo năm	Số lượng Phim và Chương trình TV được đưa vào nền tảng Netflix theo năm
Số lượng Phim Độc Quyền phát hành bởi Netflix theo Năm	Top 10 Quốc Gia có nhiều Phim và Chương Trình TV trên Netflix	Top 5 Thể loại Phổ biến trên Netflix	Top 5 Diễn viên trong các Thể loại Phim phổ biến
Top Đạo diễn có nhiều phim nhất theo loại đánh giá	Biểu đồ tương quan của Movie và TV Show về Genres		

*Hình 72: Hình ảnh giao diện nhóm chức năng **VISUALIZATION DATA***

CHƯƠNG 4: KẾT QUẢ VÀ THẢO LUẬN

4.1 Phân tích kết quả

Theo các biểu đồ và thống kê được rút ra từ quá trình phân tích tệp dữ liệu hệ thống phim trên nền tảng Netflix, ta rút ra được xu hướng cụ thể của nền tảng. Tỉ lệ phim dài tập (Movie) chiếm đa số trên Netflix. Số lượng phim và chương trình TV show đình đám được Netflix phát hành từ năm 2018 đến 2020, giao động trong khoảng từ 990 đến hơn 1200 phim. Trong đó, số lượng phim độc quyền Netflix phát hành cũng nhiều nhất vào năm 2020 với hơn 300 phim, cho thấy khoảng thời gian này Netflix chiếm thị phần người xem nhiều nhất. Thời lượng phim tập trung trong khoảng 90 đến 130 phút. Ta thấy được Top 5 thể loại được đăng tải, phần lớn phim thuộc đề tài Drama. Số lượng lớn nhất phim là phim Mỹ vượt trội với gần 2500 chương trình, số lượng diễn viên đông đảo và độ phủ sóng của họ trong những thể loại phim.

Qua quá trình thu thập, phân tích và làm sạch dữ liệu, kết quả thu được có sự chính xác về kết quả, phục vụ tốt cho các thống kê và phân tích.

4.2 Đề xuất về cải tiến quy trình phân tích

Sử dụng pipeline: Chuyển đổi từng bước trong quy trình phân tích (từ làm sạch, xử lý đến vẽ biểu đồ) thành các bước có thể lặp lại

Tự động hóa việc làm sạch dữ liệu

Sử dụng EDA (Exploratory Data Analysis), dùng thư viện như seaborn, plotly, hoặc altair để khám phá dữ liệu

Tăng cường tính chính xác của phân tích

4.3 Hướng phát triển tương lai

Bài phân tích còn nhiều hạn chế trong phạm vi phân tích do chưa thực hiện kĩ thuật crawling data, nhằm đa dạng hóa nguồn tài nguyên. Đề xuất ra các nghiên cứu tiếp theo nhằm thực hiện những hạn chế mà bài phân tích này còn vướng đọng, đồng thời áp dụng thêm nhiều công nghệ, kỹ thuật mới để theo kịp tốc độ phát triển của thế giới và tối ưu hóa quá trình thu thập và phân tích.

TÀI LIỆU THAM KHẢO

- [1] *Hartwig F., & Dearing B. E.*, (1979). *Exploratory data analysis* (Sage University Paper Series On Qualitative Research Methods, Vol. 16). NewBury Park, CA:Sage
- [2] *Wes McKinney* (2013). *Python for Data Analysis*. O'Reilly Media, CA:95472
- [3] <https://glints.com/vn/blog/eda-exploratory-data-analyst-la-gi/> ngày truy cập 16/11/2024