

Bộ giáo dục và đào tạo
Trường Đại học Ngoại ngữ - Tin học TP.HCM



BÁO CÁO ĐỒ ÁN KẾT THÚC HỌC PHẦN
Môn : Phân Tích Dữ Liệu Kinh Doanh

Đề Tài **Phân Tích Netflix Movies and TV Shows**

GVHD: Th.s Trần Phương Tuấn

23DH141469 Doãn Tuấn Tài

23DH141464 Nguyễn Bá Quang

23DH140376 Vũ Văn Hưng

Tháng 11 Năm 2025

Lời Cảm Ơn

Trong suốt quá trình thực hiện đề tài, nhóm chúng em đã luôn nhận được sự hướng dẫn nhiệt tình và những chỉ dẫn vô cùng quý giá từ thầy. Chính sự tận tâm của thầy đã giúp nhóm xác định đúng hướng triển khai, củng cố kiến thức và hoàn thiện bài làm một cách đầy đủ, khoa học. Nhân đây, nhóm xin gửi đến thầy lời cảm ơn chân thành nhất.

Nhóm em xin cảm ơn thầy Trần Phương Tuấn, người đã đồng hành và hỗ trợ chúng em từ những buổi học đầu tiên cho đến khi hoàn thiện đồ án. Thầy không chỉ cung cấp nền tảng kiến thức rõ ràng, dễ hiểu, mà còn truyền đạt nhiều kinh nghiệm thực tế có giá trị, giúp chúng em hiểu sâu hơn về các kỹ thuật xử lý dữ liệu và cách tiếp cận vấn đề một cách hợp lý.

Trong quá trình làm việc, thầy luôn dành thời gian xem xét từng phần nội dung, đưa ra những nhận xét thẳng thắn nhưng vô cùng hữu ích, giúp nhóm kịp thời sửa đổi và nâng cao chất lượng sản phẩm. Nhờ những chỉ dẫn ấy, nhóm em đã có cơ hội áp dụng lý thuyết vào thực hành và rèn luyện tư duy phân tích hiệu quả hơn.

Không chỉ là người dạy kiến thức, thầy Tuấn còn là nguồn cảm hứng lớn, giúp chúng em giữ được tinh thần cố gắng và trách nhiệm trong suốt quá trình thực hiện đề tài. Sự nhiệt huyết và tận tụy của thầy là động lực quan trọng để nhóm hoàn thành công việc một cách nghiêm túc và chính chu.

Nhóm chúng em xin gửi lời chúc đến thầy thật nhiều sức khỏe và luôn tràn đầy năng lượng để tiếp tục gắn bó với nghề. Chúng em hy vọng sẽ có thêm cơ hội được học hỏi từ thầy trong những học phần tiếp theo, để tiếp tục hoàn thiện kiến thức và kỹ năng trên con đường học tập cũng như trong sự nghiệp sau này.

MỤC LỤC

I. GIỚI THIỆU	1
1. ĐẶT VẤN ĐỀ.....	1
2. MỤC TIÊU NGHIÊN CỨU.....	1
3. PHƯƠNG PHÁP PHÂN TÍCH	2
<i>3.1. Phân Tích Mô Tả và Khám Phá Dữ Liệu</i>	<i>2</i>
<i>3.2. Bài Toán Phân Nhóm (Clustering)</i>	<i>2</i>
<i>3.3. Bài Toán Hồi Quy (Regression).....</i>	<i>3</i>
II. NỘI DUNG.....	4
III. PHƯƠNG PHÁP PHÂN TÍCH	5
IV. KẾT QUẢ PHÂN TÍCH.....	5
<i>IV.1. Mô tả tên và ý nghĩa các cột, loại dữ liệu.....</i>	<i>6</i>
<i>IV.2. Thông tin chung về dữ liệu.....</i>	<i>14</i>
<i>IV.3. Kiểm tra giá trị thiếu</i>	<i>16</i>
<i>IV.4. Outlier</i>	<i>17</i>
<i>IV.5. Mô tả thống kê dữ liệu theo cột , theo nhóm</i>	<i>20</i>
<i>IV.6. Thống kê theo loại nội dung</i>	<i>27</i>
<i>IV.7. Số lượng nội dung theo năm phát sinh</i>	<i>28</i>
<i>IV.8. Thống kê theo quốc gia.....</i>	<i>29</i>
<i>IV.9 . Thống kê theo thể loại (listed_in)</i>	<i>30</i>
<i>IV.10. Phân Nhóm.....</i>	<i>31</i>
<i>IV.11. Dự đoán tuyến tính (Linear Regression)</i>	<i>34</i>
<i>IV.12. Dự đoán phân loại.....</i>	<i>37</i>
V. KẾT LUẬN.....	40
TÀI LIỆU THAM KHẢO (IEEE)	41

DANH MỤC HÌNH ẢNH

HÌNH 1 : THỐNG KÊ MÔ TẢ	5
HÌNH 2 :THỐNG KÊ MÔ TẢ	6
HÌNH 3 : HISTOGRAM OF TYPE	7
HÌNH 4 : DATE_ADDED	8
HÌNH 5 : HISTOGRAM OF RELEASE_YEAR.....	9
HÌNH 6 : HISTOGRAM OF RATING	10
HÌNH 7 : HISTOGRAM OF DURATION.....	11
HÌNH 8 : HISTOGRAM OF LISTED_IN	12
HÌNH 9 : MA TRẬN TƯƠNG QUAN	13
HÌNH 10: KIỂM TRA THÔNG TIN CHUNG VỀ DỮ LIỆU.....	14
HÌNH 11 : KIỂM TRA GIÁ TRỊ THIỂU.....	16
HÌNH 12 : BOXPLOT DURATION	18
HÌNH 13 : BOXPLOT RELEASE YEAR TRƯỚC KHI LOẠI OUTLIER	19
HÌNH 14 : BOXPLOT RELEASE YEAR SAU KHI LOẠI OUTLIER	20
HÌNH 15 : THỐNG KÊ THEO NĂM PHÁT HÀNH	21
HÌNH 16: THỜI LƯỢNG TRUNG BÌNH PHIM THEO NĂM	22
HÌNH 17: THỐNG KÊ THEO THỜI LƯỢNG PHIM	24
HÌNH 18 : PHÂN BỐ THỜI LƯỢNG PHIM.....	25
HÌNH 19 : PHÂN BỐ LOẠI NỘI DUNG	27
HÌNH 21: SỐ LƯỢNG NỘI DUNG NĂM PHÁT HÀNH	28
HÌNH 20 : SỐ LƯỢNG THEO QUỐC GIA	29
HÌNH 21: THỐNG KÊ THEO LOẠI QUỐC GIA	29
HÌNH 22: THỐNG KÊ THEO THỂ LOẠI.....	30
HÌNH 23 : TÌM SỐ CỤM TỐI ƯU.....	32
HÌNH 24 : PHÂN NHÓM PHIM THEO NĂM	33

HÌNH 25: BIỂU ĐỒ ACTUAL VÀ PREDICTED36

HÌNH 26: BIỂU ĐỒ PHÂN BỐ SAI LỆCH37

HÌNH 27: CONFUSION MATRIX39

I. Giới thiệu

1. Đặt Vấn Đề

Trong bối cảnh ngành giải trí trực tuyến phát triển mạnh mẽ, các nền tảng cung cấp dịch vụ xem phim và chương trình truyền hình theo yêu cầu (Video on Demand) đang cạnh tranh khốc liệt. Netflix là một trong những thương hiệu tiêu biểu, sở hữu thư viện nội dung đa dạng bao gồm **Movies và TV Shows**, phục vụ lượng lớn người dùng trên toàn cầu.

Việc phân tích dữ liệu liên quan đến Netflix Movies and TV Shows đóng vai trò quan trọng trong việc hiểu rõ sự phân bố nội dung, xu hướng phát hành, cũng như đặc điểm của các loại hình chương trình. Thông qua việc khai thác và xử lý dữ liệu, nhóm có thể rút ra các insight giá trị, phục vụ cho việc đánh giá chiến lược nội dung của Netflix và xu hướng tiêu thụ giải trí của thị trường.

Do đó, báo cáo này được thực hiện nhằm phân tích toàn diện bộ dữ liệu Netflix Movies and TV Shows với cách tiếp cận có hệ thống, khoa học và phù hợp với yêu cầu của môn học.

2. Mục Tiêu Nghiên Cứu

Nghiên cứu này được thực hiện với mục tiêu phân tích toàn diện bộ dữ liệu **Netflix Movies and TV Shows**. Các mục tiêu bao gồm:

• Nhận diện xu hướng nội dung theo thời gian

Xác định sự thay đổi về số lượng và loại nội dung được phát hành mỗi năm, từ đó mô tả xu hướng tăng trưởng của Movies và TV Shows.

• Phân tích các yếu tố ảnh hưởng

Đánh giá tác động của các yếu tố như:

- Quốc gia sản xuất
- Thể loại chính
- Độ dài nội dung
- Ngày phát hành
- Đặc điểm phân loại Movies/TV Shows

đến sự hiện diện của nội dung trên Netflix.

- **Dự báo và đề xuất chiến lược**

Xây dựng mô hình dự đoán xu hướng nội dung trong tương lai, từ đó đưa ra gợi ý giúp Netflix tối ưu lựa chọn thể loại, quốc gia hợp tác và định hướng phát triển danh mục nội dung.

3. Phương Pháp Phân Tích

Nghiên cứu áp dụng các phương pháp phân tích dữ liệu hiện đại, kết hợp trực quan hóa và mô hình học máy nhằm khai thác giá trị thông tin từ bộ dữ liệu Netflix

3.1. Phân Tích Mô Tả và Khám Phá Dữ Liệu

- **Kỹ thuật sử dụng**

- Biểu đồ thời gian (Timeline)
- Biểu đồ tần suất (Countplot)
- Biểu đồ phân tán (Scatter Plot)

- **Mục đích**

- Mô tả xu hướng phát hành qua các năm.
- Quan sát sự phổ biến của từng thể loại và quốc gia sản xuất.
- Phân tích mối quan hệ giữa các biến trong dữ liệu.

3.2. Bài Toán Phân Nhóm (Clustering)

- **Mục tiêu**

Nhận diện các nhóm nội dung có đặc điểm tương đồng về thể loại, quốc gia hoặc thời điểm phát hành.

- **Kỹ thuật áp dụng**

- K-Means Clustering
- Hierarchical Clustering

- **Ứng dụng**

- Giúp phân loại danh mục nội dung theo nhóm đặc trưng.
- Hỗ trợ Netflix tối ưu thuật toán gợi ý và phát triển nội dung phù hợp với từng phân khúc

3.3. Bài Toán Hồi Quy (Regression)

- **Mục tiêu**

Dự báo xu hướng phát hành hoặc dự đoán đặc điểm nội dung trong tương lai.

- **Kỹ thuật sử dụng**

- Multiple Linear Regression
- Random Forest Regression

- **Ứng dụng**

- Dự báo số lượng nội dung theo từng năm.
- Nhận diện các yếu tố ảnh hưởng đến sự phát hành nội dung của Netflix.

3.4. Bài Toán Phân Loại (Classification)

- **Mục tiêu**

Phân loại nội dung dựa trên các đặc trưng có sẵn, ví dụ:

- Dự đoán nội dung là Movie hay TV Show.
- Phân loại nội dung theo thể loại chính.

- **Kỹ thuật sử dụng**

- Logistic Regression
- Decision Tree / Random Forest Classification

- **Ứng dụng**

- Tối ưu thuật toán gợi ý nội dung.
- Phân tích đặc điểm nổi bật của từng nhóm nội dung.
- Hỗ trợ lập kế hoạch phân bổ và phát triển danh mục nội dung.

II. Nội dung

- **Tên bộ dữ liệu** : Netflix Movies and Tv Shows
- **Nguồn Dữ Liệu** : Kaggle
- **Cấu trúc dữ liệu** : 12 cột chính , 8.807 dòng dữ liệu (mỗi dòng tương ứng một phim hoặc một TV Show)


Câu hỏi số (Số cột)	Cột tương ứng trên dataset	Nội dung
0	show_id	Mã định danh duy nhất của mỗi phim / TV Show
1	type	Loại nội dung: Movie (phim) hoặc TV Show (chương trình)
2	title	Tên phim hoặc chương trình
3	director	Tên đạo diễn; có thể để trống nếu không có thông tin
4	cast	Danh sách diễn viên tham gia
5	country	Quốc gia sản xuất phim / show
6	date_added	Ngày bộ phim/show được thêm vào Netflix
7	release_year	Năm sản xuất / phát hành
8	rating	Xếp hạng nội dung (PG, TV-MA, G...)
9	duration	Thời lượng phim hoặc số mùa của TV Show
10	listed_in	Thể loại / danh mục của phim/show
11	description	Mô tả ngắn gọn về nội dung

Bảng 1 : Cấu trúc dữ liệu

III. Phương pháp phân tích

Phần trình bày quy trình phân tích

Ví dụ:



Hình 1 : Thống kê mô tả

Nhóm bắt đầu bằng việc **lựa chọn bộ dữ liệu** và kiểm tra các thông tin cơ bản để xác định các vấn đề tổng quát. Tiếp theo, nhóm thực hiện **phân tích thăm dò dữ liệu (EDA)** nhằm giải quyết các vấn đề cơ bản. Sau khi có cái nhìn tổng quan, nhóm nhận diện được những vấn đề sâu sắc hơn từ dữ liệu và tiếp tục tiến hành **EDA chi tiết** để khai thác các thông tin này. Cuối cùng, nhóm **tổng hợp và diễn giải kết quả** để đưa ra các nhận định và định hướng nghiên cứu tiếp theo.

IV. Kết quả phân tích

Phần trình bày các kết quả phân tích (trực quan dữ liệu, trả lời các câu hỏi liên quan đến bộ dữ liệu đang phân tích)

IV.1. Mô tả tên và ý nghĩa các cột, loại dữ liệu

```
# Thống kê mô tả
df.describe(include='all')
```


	show_id	type	title	director	cast	country	date_added	release_year	rating	duration	listed_in	description
count	8807	8807	8807	6173	7692	748	8797	8807.000000	8803	8804	8807	8807
unique	8807	2	8807	4528	7692	748	1787	NaN	17	220	514	8775
top	s8807	Movie	Zubaan	Rajiv Chilaka	David Attenborough	United States	January 1, 2020	NaN	TV-MA	1 Season	Dramas, International Movies	Paranormal activity at a lush, abandoned propa...
freq	1	6131	1	19	19	2818	109	NaN	3207	1793	362	4
mean	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2014.180168	NaN	NaN	NaN	NaN
std	NaN	NaN	NaN	NaN	NaN	NaN	NaN	6.819312	NaN	NaN	NaN	NaN
min	NaN	NaN	NaN	NaN	NaN	NaN	NaN	1925.000000	NaN	NaN	NaN	NaN
25%	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2013.000000	NaN	NaN	NaN	NaN
50%	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2017.000000	NaN	NaN	NaN	NaN
75%	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2019.000000	NaN	NaN	NaN	NaN
max	NaN	NaN	NaN	NaN	NaN	NaN	NaN	2021.000000	NaN	NaN	NaN	NaN

Hình 2 :Thống kê mô tả


Cột	Ý nghĩa	Nhận xét từ dữ liệu
show_id	Mã định danh duy nhất của mỗi phim/chương trình.	Có 8807 giá trị, không trùng lặp.
type	Loại nội dung: Movie hoặc TV Show.	Có 2 loại; “Movie” chiếm 6131/8807 ($\approx 70\%$).
title	Tên phim hoặc chương trình.	8807 tên khác nhau — mỗi phim duy nhất.
director	Đạo diễn.	4528 đạo diễn khác nhau; phổ biến nhất: <i>Rajiv Chilaka</i> (19 lần).
cast	Danh sách diễn viên chính.	7692 dàn diễn viên khác nhau; phổ biến nhất: <i>David Attenborough</i> .
country	Quốc gia sản xuất.	748 quốc gia; phổ biến nhất: <i>United States</i> (2818 phim).
date_added	Ngày được thêm lên Netflix.	Có dữ liệu cho 8797 phim; giá trị phổ biến: <i>January 1, 2020</i> .
release_year	Năm phát hành.	Có giá trị từ 1925 → 2021 , trung bình khoảng 2014 .

rating	Phân loại độ tuổi (ví dụ: TV-MA, PG, R, ...).	17 loại khác nhau; phổ biến nhất: <i>TV-MA</i> (3207 phim).
duration	Thời lượng phim (phút) hoặc số mùa (Season).	220 giá trị khác nhau; phổ biến: <i>1 Season</i> .
listed_in	Thể loại (genre/category).	514 thể loại khác nhau; phổ biến: <i>Dramas, International Movies</i> .
description	Mô tả ngắn nội dung phim.	Có 8775 mô tả khác nhau — gần như phim nào cũng có mô tả riêng.


Bảng 2 : Thống kê mô tả




Hình 3 : Histogram of type




Hình 4 : Date_added




Hình 5 : Histogram of release_year




Hình 6 : Histogram of rating



Hình 7 : Histogram of duration



Hình 8 : Histogram of listed_in



Hình 9 : Ma trận tương quan

Nhận xét về ma trận tương quan giữa các cột dữ liệu Ma trận tương quan phản ánh mức độ liên hệ tuyến tính giữa các biến số trong dataset Netflix.

Sau khi xây dựng heatmap tương quan, có thể rút ra một số nhận xét quan trọng như sau: type_encoded (Movie / TV Show) Có tương quan dương nhẹ với duration_num, cho thấy TV Show (được mã hóa 1) thường có giá trị duration_num nhỏ hơn hoặc nhiều Season nên được chuyển đổi khác với Movie.

Tương quan gần như bằng 0 với release_year, rating_encoded và country_encoded, nghĩa là loại nội dung (Movie hay TV Show) không phụ thuộc rõ ràng vào năm phát hành, rating hay quốc gia. release_year .

Tương quan thấp với các biến còn lại, chứng tỏ năm phát hành không ảnh hưởng mạnh đến rating, thời lượng hay loại nội dung. duration_num Chỉ có tương quan nhẹ với type_encoded, hợp lý vì Movie có số phút cụ thể, còn TV Show thường được ghi dạng số Season → dữ liệu sau khi chuyển đổi sẽ khác. rating_encoded & country_encoded Các biến này có tương quan rất nhỏ với các biến khác.

Điều này thể hiện rằng rating và quốc gia không ảnh hưởng trực tiếp đến thời lượng hoặc năm phát hành. Tổng quan chung Các biến trong dataset có mức độ tương quan thấp, không có cặp biến nào đạt mức > 0.6 .

Điều này cho thấy dataset không bị multicollinearity (đa cộng tuyến), phù hợp để xây mô hình phân loại. Bản chất phân loại Movie/TVShow phụ thuộc vào nhiều yếu tố rời rạc hơn (genre, description, season số), nên tương quan thấp là hợp lý.

IV.2. Thông tin chung về dữ liệu

```
# Thông tin chung về dữ liệu
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8807 entries, 0 to 8806
Data columns (total 12 columns):
#   Column              Non-Null Count  Dtype
---  -
0   show_id             8807 non-null   object
1   type                8807 non-null   object
2   title               8807 non-null   object
3   director            6173 non-null   object
4   cast                7982 non-null   object
5   country             7976 non-null   object
6   date_added          8797 non-null   object
7   release_year        8807 non-null   int64
8   rating              8803 non-null   object
9   duration            8804 non-null   object
10  listed_in           8807 non-null   object
11  description          8807 non-null   object
dtypes: int64(1), object(11)
memory usage: 825.8+ KB
```

Hình 10: Kiểm tra thông tin chung về dữ liệu

Cột	Non-Null Count	Dtype	Nhận xét
show_id	8807	object	Không có giá trị thiếu — ID duy nhất cho mỗi dòng.
type	8807	object	Không có giá trị thiếu — “Movie” hoặc “TV Show”.

title	8807	object	Không có giá trị thiếu — mỗi phim có tiêu đề riêng.
director	6173	object	Bị thiếu khoảng 2634 giá trị → nhiều phim không có thông tin đạo diễn.
cast	7982	object	Bị thiếu khoảng 825 giá trị → có phim không liệt kê diễn viên.
country	7976	object	Bị thiếu 831 giá trị → không ghi rõ quốc gia sản xuất.
date_added	8797	object	Bị thiếu 10 giá trị → vài phim không có ngày thêm vào Netflix.
release_year	8807	int64	Không bị thiếu; đây là dữ liệu dạng số.
rating	8803	object	Bị thiếu 4 giá trị → vài phim không có xếp hạng độ tuổi.
duration	8804	object	Bị thiếu 3 giá trị → rất ít trường hợp không có thời lượng.
listed_in	8807	object	Không bị thiếu — mỗi phim đều có thể loại.
description	8807	object	Không bị thiếu — tất cả đều có mô tả.

Bảng 3 : Thông tin chung về dữ liệu

IV.3. Kiểm tra giá trị thiếu

	missing_count	missing_percent
show_id	0	0.00
type	0	0.00
title	0	0.00
director	2555	31.61
cast	806	9.97
country	802	9.92
date_added	8	0.10
release_year	0	0.00
rating	4	0.05
duration	0	0.00
listed_in	0	0.00
description	0	0.00
duration_num	0	0.00

Hình 11 : Kiểm tra giá trị thiếu

Cột	Số giá trị thiếu	Tỷ lệ (%)	Giải thích
director	2.555	31.61%	Nhiều chương trình TV Show không có đạo diễn duy nhất, Netflix không ghi rõ.
cast	802	9.97%	Một số phim tài liệu hoặc phim ngắn không có dàn diễn viên rõ ràng.
country	802	9.92%	Netflix không luôn ghi rõ quốc gia sản xuất.
date_added	10	0.1%	Dữ liệu nhỏ, có thể loại bỏ hoặc thay thế.
rating	4	0.05%	Một số nội dung chưa có phân loại độ tuổi.
Các cột khác	0	—	Đầy đủ dữ liệu.

Bảng 4 : Kiểm tra giá trị thiếu

• Dữ liệu dư thừa

```
df.duplicated().sum()
np.int64(0)
```


Kết quả: 0 → Không có dữ liệu trùng lặp, tập dữ liệu sạch.

Dữ liệu ngoại lai (Outlier)

IV.4. Outlier

Outlier Duration trước xử lý


- duration_num: 2 giá trị outlier (0.02%)



Hình 12 : Boxplot Duration


Outlier Release Year trước xử lý

- release_year: 719 giá trị outlier (8.16%)



Hình 13 : Boxplot Release Year trước khi loại outlier

Outlier sau khi xử lý duration_num : 2 giá trị outlier bị loại




Hình 14 : Boxplot Release Year sau khi loại outlier

- release_year: 719 giá trị outlier bị loại


Số dòng còn lại sau xử lý outlier: 8083

IV.5. Mô tả thống kê dữ liệu theo cột , theo nhóm

Thống kê theo năm phát hành:



Hình 15 : Thống kê theo năm phát hành



Hình 16: Thời lượng trung bình phim theo năm

Nhận xét về thống kê theo năm phát hành:

1. Số lượng phim theo năm

- a. Dữ liệu có 73 năm khác nhau, từ 1942 đến 2021.
- b. Số lượng phim phát hành tăng dần theo thời gian, đặc biệt từ những năm 2000 trở đi, với các năm gần đây như 2017–2018 có hơn 700 phim mỗi năm, cho thấy sự bùng nổ sản xuất nội dung trong kỷ nguyên streaming.

2. Tuổi trung bình của các phim

- a. Tuổi trung bình của phim (giả sử cột mean là tuổi của phim khi thống kê) dao động khá rộng.
- b. Ở các năm cũ (1940s), tuổi trung bình dao động từ ~35 đến 62, thể hiện sự đa dạng về thời lượng hoặc mức phổ biến của phim khi ra mắt.
- c. Ở các năm gần đây (2017–2021), tuổi trung bình tập trung quanh 92–96, cho thấy hầu hết phim mới đều thuộc nhóm tuổi tương tự, với sự ổn định hơn.


3. Độ lệch chuẩn (std)

- a. Ở các năm cũ, độ lệch chuẩn khá cao (từ ~16 đến ~24), nghĩa là tuổi của các phim trong cùng năm có sự biến động lớn.
- b. Ở các năm gần đây, độ lệch chuẩn dao động từ ~25–30, vẫn còn tương đối cao, cho thấy vẫn tồn tại sự khác biệt đáng kể giữa các phim mới, nhưng mức trung bình vẫn ổn định.


4. Xu hướng tổng quan

- a. Có thể nhận thấy một xu hướng tăng về số lượng phim theo thời gian.
- b. Tuổi trung bình phim gần đây ổn định hơn so với các năm đầu, mặc dù vẫn còn dao động nhất định.
- c. Điều này phản ánh cả sự phát triển ổn định của ngành công nghiệp điện ảnh hiện đại và sự đồng đều hơn về đối tượng khán giả mà phim hướng tới.

Thống kê theo thời lượng phim



Hình 17: Thống kê theo thời lượng phim



Hình 18 : Phân bố thời lượng phim

Nhận xét về thời lượng phim (duration_min):

1. Số lượng dữ liệu:

- a. Có tổng cộng 5.482 phim được thống kê về thời lượng, đủ lớn để phân tích.

2. Thời lượng trung bình và phân bố:

- a. Thời lượng trung bình của phim là khoảng 97,7 phút, gần với giá trị trung vị (97 phút), cho thấy phân bố thời lượng phim khá cân đối.
- b. 25% phim có thời lượng ≤ 86 phút, 50% ≤ 97 phút, và 75% ≤ 112 phút. Như vậy, phần lớn phim (giữa 25%–75%) nằm trong khoảng 86–112 phút.


3. Độ biến thiên:

- a. Độ lệch chuẩn khoảng 26,7 phút, cho thấy có sự đa dạng về thời lượng, từ phim ngắn 3 phút đến phim dài 214 phút.
- b. Một số phim rất ngắn hoặc rất dài tạo ra khoảng cách đáng kể so với trung bình, nhưng chúng chiếm phần nhỏ trong tổng thể.

4. Tóm tắt:

- a. Hầu hết phim có thời lượng khoảng 1,5–2 giờ, phù hợp với thói quen xem phim phổ biến.
- b. Dữ liệu cũng phản ánh sự đa dạng về thể loại, từ phim ngắn đến phim bom tấn dài hơn 3 giờ.

IV.6. Thống kê theo loại nội dung




Hình 19 : Phân bố loại nội dung

Loại	Số lượng	Tỷ lệ (%)
Movie	6131	69.6%
TV Show	2676	30.4%

Bảng 7 : Thống kê theo loại nội dung
=> Tốc độ tăng trưởng TV Show nhanh hơn Movie trong giai đoạn gần đây, thể hiện xu hướng ưu tiên phát triển nội dung dạng series.

IV.7. Số lượng nội dung theo năm phát hành



Hình 21: Số lượng nội dung năm phát hành


Kết quả:

- Nội dung tập trung nhiều từ 2015–2021.
- Cho thấy xu hướng Netflix bổ sung nội dung mới mạnh mẽ trong giai đoạn gần đây.

IV.8. Thống kê theo quốc gia

```
Top 10 quốc gia có nhiều nội dung nhất:  
country  
United States    3689  
India            1046  
United Kingdom   804  
Canada           445  
France           393  
Japan            318  
Spain            232  
South Korea      231  
Germany          226  
Mexico           169  
Name: count, dtype: int64
```

Hình 20 : Số lượng theo quốc gia




Hình 21: Thống kê theo loại quốc gia

Quốc gia	Số lượng nội dung
United States	~2818
India	~972
United Kingdom	~419
Japan	~226
South Korea	~182

Bảng 10 : Bảng thống kê theo loại quốc gia

=> Từ kết quả cho thấy Mỹ và Ấn Độ là hai quốc gia có số lượng nội dung lớn nhất.

IV.9 . Thống kê theo thể loại (listed_in)



Hình 22: Thống kê theo thể loại

Thể loại	Số lượng
Dramas	2100+
Comedies	1600+
Documentaries	800+
Action & Adventure	700+


International Movies	650+
----------------------	------

Bảng 11: Thống kê theo thể loại

IV.10. Phân Nhóm

Các tiêu chí dùng để phân nhóm gồm:


- **release_year** – năm phát hành của phim, phản ánh xu hướng theo thời gian (phim cũ và phim mới).
- **duration_min** – thời lượng phim (tính bằng phút), biểu thị độ dài của nội dung.
- **country** – quốc gia sản xuất phim, được mã hóa thành giá trị số để phản ánh yếu tố văn hoá và khu vực.



Hình 23 : Tìm số cụm tối ưu

Dữ liệu được **chuẩn hóa bằng StandardScaler** để đưa các biến về cùng thang đo, sau đó áp dụng dụng **thuật toán K-Means** để phân cụm. Số lượng cụm tối ưu được xác định bằng **Elbow Method**, trong đó độ lệch (inertia) giảm rõ rệt tại $k = 3$ nên chọn **3 cụm**.

```
X = data_cluster[['release_year', 'duration_min', 'country_encoded']]
```



Hình 24 : Phân nhóm phim theo năm

Biểu đồ phân tán theo release_year và duration_min cho thấy các cụm được phân tách rõ ràng, phản ánh xu hướng phát triển phim theo thời gian và khu vực.

Kết quả cho thấy các phim được chia thành ba nhóm chính:

Cluster 0 (Xanh) – Phim truyền thống, thời lượng ổn định Tập trung từ 1940 → 2005
Thời lượng chủ yếu 80–150 phút, một số >200 phút Nhóm chiếm số lượng nhiều nhất
Insight:

Đây là nhóm phim điện ảnh cổ điển, phát triển lâu dài với thời lượng tiêu chuẩn của phim chiếu rạp nhiều thập kỷ trước. Phân bố rộng phản ánh sự đa dạng và số lượng lớn phim truyền thống.

Cluster 1 (Cam) – Phim hiện đại, thời lượng vừa Tập trung từ 2005 → 2020 Thời lượng ~70–130 phút Nhóm nhỏ hơn Cluster 0 Insight: Đại diện cho phim hiện đại với thời lượng tối ưu (~100 phút), phản ánh xu hướng gọn nhẹ, dễ tiếp cận, phù hợp streaming và nhu cầu đại chúng.

Cluster 2 (Xanh tím) – Phim mới & phim ngắn Xuất hiện mạnh từ 2010 → 2020 Thời lượng <70 phút, nhiều phim chỉ 20–40 phút Insight: Nhóm phim ngắn, nổi bật với nội dung trực tuyến và short film. Phản ánh rõ xu hướng streaming bùng nổ, càng hiện đại càng nhiều phim ngắn

IV.11. Dự đoán tuyến tính (Linear Regression)

Dự đoán thời lượng phim (*duration_min*) dựa trên các đặc điểm khác của phim. Mục tiêu nhằm xác định xem **những yếu tố nào ảnh hưởng đến độ dài trung bình của phim** trên Netflix.

Biến mục tiêu (Target variable):

- *duration_min* – Thời lượng phim (phút).

Các biến đầu vào (Independent variables):

Biến	Kiểu dữ liệu	Giải thích
<i>release_year</i>	Numeric	Năm phát hành phim
<i>country</i>	Categorical	Quốc gia sản xuất

listed_in	Text	Thể loại nội dung (Drama, Comedy, Documentary, v.v.)
type	Constant	Luôn là “Movie”, nên không cần đưa vào mô hình

Bảng 12 : Các biến đầu vào

Chỉ sử dụng các bản ghi có `type == 'Movie'` để đảm bảo dữ liệu đồng nhất, vì các **TV Show** có thời lượng tính bằng **số mùa (Seasons)** nên không thể so sánh trực tiếp với phim tính bằng **phút**.

```
# Lọc phim có dữ liệu đầy đủ
movies = df[df['type'] == 'Movie'].copy()
movies = movies.dropna(subset=['duration', 'country', 'release_year'])
movies['duration_min'] = movies['duration'].str.replace(' min', '').astype(float)

# Mã hóa country
le = LabelEncoder()
movies['country_code'] = le.fit_transform(movies['country'])

# Biến độc lập và phụ thuộc
X = movies[['release_year', 'country_code']]
y = movies['duration_min']

# Chia dữ liệu train/test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Huấn luyện mô hình
model = LinearRegression()
model.fit(X_train, y_train)

# Dự đoán
y_pred = model.predict(X_test)

# Đánh giá mô hình
mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print("Mean Absolute Error:", round(mae, 2))
print("R² Score:", round(r2, 2))

Mean Absolute Error: 18.51
R² Score: 0.09
```

=> MAE = 18.51 phút → Sai số trung bình khoảng 18,5 phút.


=> $R^2 = 0.09$ → Mô hình chỉ giải thích được khoảng 9% biến thiên của thời lượng phim, tức là mức độ dự đoán yếu, nhưng vẫn hợp lý với dạng dữ liệu này (vì thời lượng phim phụ thuộc vào nhiều yếu tố không có trong dataset, như thể loại con, đạo diễn, ngân sách, v.v.).

```
import matplotlib.pyplot as plt
import seaborn as sns

# 1 Biểu đồ so sánh giá trị thực tế và dự đoán
plt.figure(figsize=(6,6))
sns.scatterplot(x=y_test, y=y_pred, alpha=0.6)
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], '--', color='red')
plt.title('Biểu đồ Actual vs Predicted Duration')
plt.xlabel('Thời lượng thực tế (phút)')
plt.ylabel('Thời lượng dự đoán (phút)')
plt.grid(True)
plt.show()

# 2 Biểu đồ phân bố sai số (residuals)
residuals = y_test - y_pred
plt.figure(figsize=(6,4))
sns.histplot(residuals, bins=30, kde=True, color='skyblue')
plt.title('Phân bố sai số dự đoán (Residuals)')
plt.xlabel('Sai số (phút)')
plt.ylabel('Tần suất')
plt.grid(True)
plt.show()
```

Biểu đồ 1 (Actual vs Predicted):




Hình 25: Biểu đồ Actual và Predicted

Các điểm dữ liệu nằm rải rác xung quanh đường chéo cho thấy mô hình dự đoán có độ

khớp trung bình.
Tuy nhiên, phần lớn điểm nằm xa đường chuẩn $\rightarrow$ mô hình chưa thể hiện mối quan hệ tuyến tính mạnh giữa các biến đầu vào và thời lượng phim.

Biểu đồ 2 (Residuals):



Hình 26: Biểu đồ Phân bố sai lệch

Phân bố sai số có dạng gần chuẩn, trung tâm quanh 0, cho thấy mô hình không bị lệch hẳn về một phía (không underfit hoặc overfit nghiêm trọng). Tuy nhiên, biên độ sai số khá rộng ($\sim \pm 30$ phút), chứng tỏ cần thêm các biến giải thích khác (như thể loại hoặc đánh giá độ tuổi) để cải thiện độ chính xác.

IV.12. Dự đoán phân loại

```
# Features chọn để phân loại
X = df[['release_year', 'duration_num', 'rating_encoded', 'country_encoded']]
y = df['type_encoded']
```

	Accuracy: 0.999				
	Classification Report:				
		precision	recall	f1-score	support
	Movie	1.00	1.00	1.00	1195
	TV Show	1.00	1.00	1.00	566
	accuracy			1.00	1761
	macro avg	1.00	1.00	1.00	1761
	weighted avg	1.00	1.00	1.00	1761


Nhận xét kết quả phân loại Trong mô hình phân loại này, Nhóm sử dụng các đặc trưng gồm: release_year – năm phát hành duration_num – thời lượng phim rating_encoded – mã hóa đánh giá country_encoded – mã hóa quốc gia Mục tiêu phân loại là cột type_encoded (Movie / TV Show).

Sau khi huấn luyện mô hình Random Forest, kết quả đánh giá trên tập dữ liệu kiểm tra cho thấy: Độ chính xác (Accuracy): 0.999, cho thấy mô hình phân loại gần như hoàn hảo. Precision, Recall, F1-score cho từng lớp đều đạt giá trị 1.00, nghĩa là cả hai lớp Movie và TV Show đều được mô hình nhận dạng chính xác tuyệt đối.

Macro Average và Weighted Average cũng đều đạt 1.00, cho thấy mô hình hoạt động ổn định và không bị lệch về bất kỳ lớp nào. Nhận xét ý nghĩa: Các đặc trưng đã chọn có khả năng phân biệt giữa phim điện ảnh và chương trình truyền hình rất tốt.

Mô hình Random Forest thể hiện hiệu quả cao trong việc xử lý dữ liệu hỗn hợp (số và biến mã hóa). Kết quả gần như hoàn hảo cho thấy dữ liệu ít nhiễu và phân tách rõ ràng giữa hai loại nội dung.

Hình 27: Confusion Matrix



V. Kết luận

- Trong suốt quá trình làm việc, nhóm đã hoàn tất việc phân tích thăm dò dữ liệu (EDA) trên tất cả các thuộc tính của bộ dữ liệu Netflix, bao gồm các thông tin cơ bản như loại nội dung, năm phát hành, quốc gia sản xuất, thời lượng và xếp hạng nội dung. Nhóm đã tiến hành tìm hiểu và phân tích sâu hơn các vấn đề phát sinh sau khi EDA cơ bản, từ đó rút ra những nhận định giá trị về xu hướng phát triển nội dung trên Netflix. Toàn bộ các phân tích chi tiết sẽ được trình bày trong source code đi kèm.
- Thông qua quá trình phân tích, nhóm đã trả lời được nhiều câu hỏi quan trọng liên quan đến lĩnh vực phân tích dữ liệu và Media Streaming, chẳng hạn như:
 - Thể loại nội dung nào phổ biến nhất trên Netflix?
 - Quốc gia nào có nhiều nội dung được sản xuất nhất?
 - Có mối quan hệ nào giữa năm phát hành và loại nội dung?
 - Xu hướng phát triển nội dung theo từng thập kỷ là gì?
 - Những kết quả này không chỉ giúp nhóm hiểu rõ hơn về xu hướng và sở thích người dùng Netflix, mà còn cung cấp những thông tin quan trọng có thể ứng dụng trong các nghiên cứu về truyền thông, giải trí, và phân tích hành vi người dùng.

Tài liệu tham khảo (IEEE)

- [1] G. Sparks, “An Introduction to modelling software systems using the Unified,” 2000.
[Trực tuyến]. Available: <http://www.sparxsystems.com.au/>,.
- [2] D. L. R. LeMaster, Object-Oriented Programming & Design”, CSCI 4448, University of Colorado, 2002.
- [3] K. S. M. Fowler, UML Distilled Second Edition – A Brief Guide to the Standard Object Modelling Language, Addison Wesley Book, 1999.
- [4] A. M.-M. P. N. J. S. L. Mathiassen, ObjectOriented Analysis&Design (OOA&D) – Concept, Principles & Methodology.
- [5] “UML Notion Guide,” [Trực tuyến]. Available: <http://etna.int-evry.fr/COURS/UML/notation/index.html>.
- [6] Đ. V. Đức, Phân tích thiết kế hướng đối tượng bằng UML, HCM: Nhà xuất bản Giáo dục, 2001.
- [7] D. A. Đức, Bài giảng Phân tích thiết kế hướng đối tượng sử dụng UML, HCM: Đại học KHTN - Đại học Quốc gia TP. HCM, 2000.
- [8] N. V. Ba, Phát triển hệ thống hướng đối tượng với UML 2.0 và C++, Hà Nội: Nhà xuất bản Đại học Quốc gia Hà Nội, 2005.